트리 기반 머신러닝 기법을 활용한 포트홀 발생 주요 요인 분석

문예린, 김수아, 박서진, 이나경, 이지현, 이채은, 최예림*
서울여자대학교

{myr87344548, ksua0923, seoj1npark, e4kyeong1121, lucy567888, celee, *yerim.choi}@swu.ac.kr

Analysis of the Key Factors of Potholes Using Tree-Based Machine Learning Techniques

Yerin Moon, Sua Kim, Seojin Park, Nakyeong Lee, Jeehyeon Lee, Chaeeun Lee, Yerim Choi*
Seoul Women's Univ.

요 약

최근 포트홀 발생이 급증하면서 도로 안전 문제와 유지보수 비용 부담이 심화되고 있다. 이에 본 논문은 서울시 데이터를 기반으로 포트홀 발생 요인을 분석하여 도로 유지보수 효율성을 높이고자 하였다. 기상 조건, 도로 특성, 교통량 등의 데이터를 수집 및 전처리한 뒤, 트리 기반 머신러닝 모델(XGBoost, LightGBM, CatBoost)을 활용하여 변수 중요도를 평가하였다. 분석 결과 LightGBM이 78%의 예측 정확도와 0.81의 F1-Score로 가장 균형 잡힌 성능을 보였으며, 주요 요인으로 풍속, 교통량 등이 확인되었다. 본 연구는 포트홀 예방 및 관리에 유용한 데이터 기반 통찰을 제공할 것으로 기대된다.

Ⅰ. 서 론

포트홀이란, 도로 표면 일부가 부서지거나 내려앉아 생긴 국부적인 구멍으로, 차량의 타이어와 휠 파손, 공기압 손실 등 물리적 손상을 초래할 뿐 아니라 교통사고의 위험성을 높이는 주요 요인이다[1]. 서울시 보고에 따르면, 2024년 1월과 2월 동안 서울시에서 발생한 포트홀 건수는 9,124건으로, 이는 전년 동월 대비 약 두 배에 달한다. 또한, 최근 3년간 서울시에서 약 71,000건의 포트홀이 복구되었으나, 사후 조치에 머물렀으며 예방적 관리 체계는 미흡한 상황이다. 이를 해결하기 위해 포트홀 발생 요인을 체계적으로 분석하고 예방적 관리 방안을 마련할 필요가 있다.

포트홀은 도로 안전과 유지보수 효율성에 중대한 영향을 미치는 중요한 요소로, 이를 분석하기 위한 다양한 연구가 이루어져 왔다. Asad 외(2022)는 차량 센서를 활용해 실시간으로 포트홀을 탐지하고 발생 시점을 정확히 파악하여 포트홀로 인한 피해를 줄이고자 하였다[2]. 또한, Llopis-Castelló 외(2020)는 미국과 캐나다의 도로 구간을 대상으로 기상 조건, 교통량, 포장 구조 등의 다중 요인이 도로 열화에 미치는 영향을 분석하며, 복합 데이터를 활용한 예측 모델의 필요성을 제기하였다[3].

본 연구는 선행연구의 시사점을 바탕으로 서울시 데이터를 활용하여 포트홀 발생에 영향을 미치는 요인을 체계적으로 분석하고자 한다. 기상 데이터, 도로 특성, 교통량 등 다양한 데이터를 수집하고, 트리 기반 머신러닝 모델을 활용하여 변수의 중요도를 평가함으로써 효과적인 예방 대책 수립과 도로 유지보수 설계에 기여하고자 한다.

Ⅱ. 본론

2.1 데이터 및 실험 설계

포트홀 발생 요인을 분석하기 위해, 2022년 12월부터 2024년 1월까지 서울지역의 포트홀 발생 요인과 관련된 다양한 데이터들을 수집하고 통합하였다. 최종적으로 333,858건의 데이터(37개 변수)가 확보되었으며, 이는 월별 약 23,847개의 데이터를 포함한다. 데이터는 포트홀 발생 여부를 타겟 변수로 설정하고, 공간적 병합 및 월 단위 시간 축 정렬을 통해 분석에 적합한 형태로 구성하였다. 사용된 주요 데이터셋과 수집처는 표 1과 같다.

표 1. 포트홀 발생 분석에 활용된 데이터셋

데이터	설명	수집처
포트홀	포트홀 보수 등록 날짜, 발생 위치, 발생 횟수 등	서울시 열린데이터 광장
도로 네트워크	도로 고유 번호, 도로 등급, 도로 유형, 도로 사용 여부, 통행 제한 차량 등	국토교통부 ITS 국가교통정보센터
도로 특성	도로 경사도, 결빙 구간 여부 등	국토지리정보원 국토정보플랫폼, 행정안전부
도로 위험 지수	차종별 도로 위험 점수(1~4등급)	한국도로공사
돌발상황	교통사고, 공사, 재난 등 도로 돌발 상황	국토교통부 ITS 국가교통정보센터
교통량	도로별 유입 및 유출 교통량	서울특별시 교통정보센터
버스 정보	노선 정보, 정류장별 운행 횟수, 버스 전용 차로 여부	서울특별시 미래첨단교통과, 서울 열린데이터광장
기상 상태	강수량, 강수 유형, 평균 온도, 습도, 풍속	기상청 기상자료개방포털

수집된 데이터는 분석 모델에 적합하도록 전처리하였다. 연속형 변수(예: 기상, 교통량)의 결측값은 데이터의 분포를 유지하면서 분석 결과의 왜곡을 최소화하기 위해 평균값으로 대체하였다. 일부 범주형 변수(예: 강수 유형)는 대표성을 고려하여 최빈값으로 처리하였다. 이후, 모든 범주형 변수에 원-핫 인코딩(One-Hot Encoding)을 적용하여 데이터 전처리를 진행하였다. 모든 데이터를 월 단위로 집계하여 데이터의 일관성을 확보한 후, 도로 구간별 포트홀 발생 여부를 포함한 데이터셋을 구축하였다.

2.2 방법론

본 연구에서는 포트홀 발생 요인을 분석하기 위해 트리 기반 머신러닝 모델(XGBoost, LightGBM, CatBoost)을 활용하였다. 이러한 모델들은 비선형적 관계와 데이터의 복잡성을 효과적으로 처리하며, 변수 간 상호작용을 심층적으로 분석하는 데 적합하다. 또한, 결측치 처리에 강점이 있어 신뢰도 높은 분석 도구로 활용된다. 기존 연구에서도 트리 기반 모델의 유용성이 입증되었다. 예를 들어, 이민영 외(2023)는 XGBoost를 활용하여 포장 보수가 필요한 지역을 예측하고 포트홀 발생에 영향을 미치는 주요 요인을 분석함으로써, 트리 기반 모델이 복잡한 데이터 환경에서도 중요한 변수들을 효과적으로 식별할 수 있음을 보여주었다[4].

이를 기반으로, 서울시의 포트홀 발생 요인을 분석하기 위해 다양한 데이터를 수집하고, 공간 좌표 매핑(Geospatial Mapping)과 도로 네트워크 링크 기반 매핑(Road Network Link-based Mapping) 기법을 활용해 데이터를 통합하였다. 공간 좌표 매핑은 포트홀 발생 위치를 위도와 경도로 변환해 지도 상에서 분석할 수 있도록 하며, 도로 네트워크 링크 기반 매핑은 도로 구간별 데이터를 연결하여 교통량 및 기상 요인 등 다양한 변수들을 종합적으로 반영한다. 이 과정에서 데이터의 공간적 및 네트워크 특성을 보존하고, 분석 모델에 적합한 형태로 데이터를 정리하였다. 통합된 데이터를 바탕으로 트리 기반 모델을 사용하여 발생 가능성을 예측하고, 특성 중요도를 분석해 주요 변수의 영향을 체계적으로 평가하고자 한다.

2.3 실험 및 결과

본 연구에서는 포트홀 발생 여부를 예측하기 위해 데이터 전처리와 모델 학습 단계를 진행하였다. 데이터 불균형을 해결하기 위해 다수 클래스(Class 0, 포트홀 미발생) 데이터를 소수 클래스(Class 1, 포트홀 발생)와 동일한 비율(1:1)로 언더샘플링하여 균형 잡힌 학습 데이터셋을 생성하였다. 결측치가 포함된 열 중 결측 비율이 높거나 대체가 어려운 데이터는 제거하여 분석의 신뢰성을 확보하였다. 이후, 전처리가 완료된 데이터는 학습 데이터와 테스트 데이터로 8:2 비율로 분할하였으며, 학습 데이터는 모델 학습 및 하이퍼파라미터 튜닝에, 테스트 데이터는 최종 성능 평가에 활용하였다.

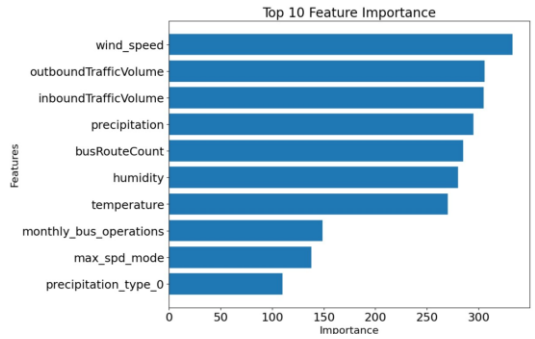
각 모델(XGBoost, LightGBM, CatBoost)의 하이퍼파라미터 최적화는 GridSearchCV를 사용하여 진행하였으며, Precision, Recall, F1-Score 간의 균형을 고려해 Precision-Recall Curve를 기반으로 최적의 임계값(Threshold)을 설정하였다. 모델 성능은 Precision, Recall, F1-Score, Accuracy, AUC를 기준으로 평가되었으며, 결과는 표 2와 같다.

표 2. 포트홀 발생 여부 예측 모델 성능

Class		0 (포트홀 미발생)	1 (포트홀 발생)	Accuracy	AUC
XGBoost	Precision	0.86	0.73	0.78	0.86
	Recall	0.66	0.89		
	F1-Score	0.75	0.80		
LightGBM	Precision	0.87	0.73	0.78	0.84
	Recall	0.67	0.90		
	F1-Score	0.75	0.81		
CatBoost	Precision	0.86	0.73	0.78	0.86
	Recall	0.66	0.90		
	F1-Score	0.75	0.80		

세 모델은 유사한 성능을 보였으나, LightGBM은 클래스 간 Precision과 Recall의 균형을 잘 맞추어 Class 0과 Class 1에 대해 높은 F1-Score를 기록하며 가장 균형 잡힌 성능을 보였다. 반면, XGBoost와 CatBoost는 AUC에서 더 높은 점수를 보여 클래스 구분 능력이 뛰어남을 보여주었다.

그림 1. LightGBM 분석: 상위 10개 변수 중요도 그래프



LightGBM 모델의 해석 가능성을 활용하여 포트홀 발생에 영향을 미치는 주요 변수의 중요도를 분석하였다. 분석 결과, 풍속(wind_speed)이 가장 높은 특성 중요도를 보였다. 이는 풍속이 태풍과 같은 기상 악화와 도로 환경에 다양한 영향을 미치기 때문에 포트홀 발생의 요인으로 작용할 가능성을 시사한다. 특히 풍속은 도로 표면의 수분증발과 균열 내부의 수분 침투를 가속화할 수 있어 포트홀 발생에 영향을 미칠 수 있다[5]. 이어서 유출 교통량(outboundTrafficVolume)과 유입 교통량(inboundTrafficVolume)이 중요 변수로 도출되었다. 이는 도로 이용량 증가가 도로에 가해지는 하중과 물리적 손상에 영향을 미친다는 점을 의미한다. 버스 운행 노선 수(busRouteCount) 또한 대중교통과 같은 중대형 차량의 빈번한 운행이 도로 손상을 야기해 포트홀 발생 가능성을 높인다는 점을 보여주었다.

이 외에도 강수량(precipitation), 기온(temperature), 습도(humidity) 등과 같은 기상 요인이 주요 변수로 나타났다. 이는 이상기후가 도로표면의 반복적인 팽창과 수축을 유발하여 도로 구조를 약화시키는 주요 원인임을 확인할 수 있는 결과이다.

Ⅲ. 결론

본 연구는 서울시 데이터를 수집 및 전처리하고, 트리기반 머신러닝 모델을 활용하여 포트홀 발생 요인을 분석하였다. 분석 결과, 주요 요인으로 풍속, 교통량, 버스 운행 노선 수, 강수량 등을 도출하였다. 특히, 풍속은 기존 연구에서 다루지 않았던 기상 요소로, 추가적인 영향 요인을 밝혀냈다는 점에서 의의가 있다. LightGBM 모델은 포트홀 발생 가능성을 효과적으로 예측하고 주요 요인을 분석하는 데 뛰어난 성능을 보였다. 이를 통해 포트홀 발생 위험이 높은 구간을 사전에 예측하고 우선순위를 설정하여 도로 관리 정책에 데이터 기반 접근 방식을 도입할 수 있다. 더불어 도로 유지보수 시점과 자원을 효율적으로 배분할 수 있으며, 장기적으로 도로의 안정성을 강화하고 교통사고를 예방하며 유지보수 비용 절감에도 기여할 수 있을 것으로 기대된다.

참 고 문 헌

[1] Safyari, Y., Mahdianpari, M., & Shiri, H. (2024). A Review of Vision-Based Pothole Detection Methods Using Computer Vision and Machine Learning. Sensors, 24(17), 5652.

[2] Abed, A., Rahman, M., Thom, N., Hargreaves, D., Li, L., & Airey, G. (2023). Analysis and Prediction of Pothole Formation Rate Using Spatial Density Measurements and Pavement Condition Indicators. Transportation Research Record, 2677(11), 651-664.

[3] Llopis-Castelló, D., García-Segura, T., Montalbán-Domingo, L., Sanz-Benlloch, A., & Pellicer, E. (2020). Influence of Pavement Structure, Traffic, and Weather on Urban Flexible Pavement Deterioration. Sustainability, 12(22), 9717.

[4] Lee, M., Choi, J., Kim, I., Son, S., & Choi, I. (2023). Priority area prediction service for local road packaging maintenance using spatial big data. Journal of Intelligence and Information Systems, 29(3), 79- 101,

[5] Kim, T.-K., Cho, C.-M., Choi, J.-H., & Kim, J.-H. J. (2016, October 31). Performance Based Evaluation of Concrete Chloride Diffusion Resistance from Wind Speed-Sunlight Exposure Time Curing Conditions of Climate Change. Journal of the Korea Concrete Institute. Korea Concrete Institute.