게임 속 AI 시스템 영향 평가

Activision - ToxMod Voice Moderation AI 를 중심으로

박소현 데이터사이언스학과
이주원 데이터사이언스학과
이지현 데이터사이언스학과
임지원 문헌정보학과

서울여자대학교
2025.12.17

목차

목차 **1**
Ⅰ. 평가 주체 **2**
1. 평가 주체의 구성 및 전문성 2
Ⅱ. 평가 대상 및 이해관계자 **2**
1. 평가 대상 개요 2
2. 기술적 특성 및 데이터 처리 과정 3
3. 주요 이해관계자 분석 3
Ⅲ. 평가 방법 및 자료 **4**
1. 평가 방법 및 절차 4
2. 활용 자료(내부·외부) 5
Ⅳ. 평가 내용 **5**
1. 적용 윤리 원칙 개요 5
2. 윤리 원칙별 분석 5
2.1. 프라이버시 및 데이터 거버넌스 5
2.2. 공정성 8
2.3. 투명성 12
3. 윤리적 딜레마 제시 15
Ⅴ. 개선 사항 및 후속 조치 제안 **15**
1. 윤리적 문제에 대한 개선 방안 15
2. 제도적·기술적 보완 사항 15
3. 평가의 한계 및 제약사항 16
4. 후속 조치 및 정책 제언 16
참고문헌 **17**

Ⅰ. 평가 주체

1. 평가 주체의 구성 및 전문성

본 윤리 영향 평가는 데이터사이언스 관련 교과목을 수강하는 학생들이 팀을 이루어 진행하였다. 평가팀에는 데이터사이언스 전공을 바탕으로 정보 보안과 데이터 보호 문제에 이해를 갖춘 구성원과, 문헌정보학 전공을 기반으로 정보시스템과 정보 검색 구조에 대한 학문적 배경을 갖춘 구성원으로 이루어져있다. 이러한 전공 경험은 데이터 처리, 개인정보 보호 정책, AI 시스템 설계와 운영 구조를 이해하고 분석하는 데 기본적인 전문성을 더해주었다.

평가팀은 특히 음성 기반 인공지능 시스템에서 다뤄지는 데이터의 민감함과, 자동화된 판단이 이용자에게 미칠 수 있는 영향에 집중해 자료를 살펴보았다. 음성 데이터가 수집되고 처리·보관되는 과정에서 생길 수 있는 개인정보 보호 문제와, AI가 대화 내용을 분석해 제재 여부를 정하는 구조가 가진 윤리적 의미를 주요하게 짚었다. 또한, 수업에서 다룬 인공지능 윤리의 핵심 원칙과 평가 기준을 바탕으로 하여 기술적 성능 자체보다는 시스템 설계와 운영 방식이 사회적, 윤리적 가치에 어떤 영향을 미치는지에 초점을 맞춰 분석했다. 특히 AI 기반 음성 중재 시스템이 온라인 게임 환경에서 이용자 경험과 신뢰를 쌓는 데 어떤 역할을 하는지에 집중하였다.

결국 이번 평가는 학습의 일환으로 이루어진 윤리 영향 평가로, 대상 시스템의 윤리적 쟁점과 사회적 의미를 정리하고 앞으로 개선해야 할 방향을 고민해보는 데 의의가 있다.

Ⅱ. 평가 대상 및 이해관계자

1. 평가 대상 개요

본 평가는 게임 내 음성 채팅 환경에서 발생하는 욕설, 혐오 발언, 괴롭힘 같은 유해 발화를 실시간으로 탐지하고 관리하기 위해 개발된 인공지능 음성 중재 시스템, ToxMod Voice Moderation AI를 대상으로 한다.[1] 이 시스템은 Modulate 사가 개발했으며, Activision 이 이를 도입해 Call of Duty: Modern Warfare II 와 Call of Duty: Warzone 등 주요 게임에서 직접 운영 중이다.[2][3][4] ToxMod는 대규모 다중 이용자가 참여하는 온라인 게임 환경, 특히 1인칭 슈팅 게임의 음성 채팅을 주요 적용 대상으로 삼고 있다. 경쟁이 치열한 FPS 게임에서는 음성 채팅을 통한 공격적 발언이나 괴롭힘이 자주 발생해왔고, Activision은 많은 글로벌 이용자가 모이다 보니 이런 문제가 더 커질 수밖에 없었다고 언급했다. 그래서 기존에 이용자 신고에 의존하던 방식의 한계를 보완하고, 보다 즉각적인 대응이 가능한 기술적 해결책으로 이 시스템을 도입하게 되었다.[5] 이 시스템은 게임 중 오가는 음성 채팅 데이터를 받아 텍스트로 변환한 뒤, 인공지능 모델로 발화의 내용과 맥락을 분석한다. 단순히 키워드만 찾는 방식이 아니라, 발화의 어조, 감정, 음색, 대화 흐름 등 여러 요소를 종합적으로 고려하도록 설계되었다. 이 시스템은 욕설, 혐오 발언, 성희롱, 괴롭힘 같은 다양한 유형의 유해 발언을 실시간으로 탐지하는 것이 목표이다.[6]

---

[1] Modulate. (n.d.). *Toxmod.*
[2] Chin, M. (2023). *Call of Duty will use AI to moderate voice chats*. The Verge.
[3] Edwards, B. (2023). *AI-powered hate speech detection will moderate voice chat in Call of* Duty. Ars Technica.
[4] Modulate. (n.d.). *Modulate and Activision Case Study.* Modulate.
[5] Call of Duty Staff. (2023). *유해성 근절 진행 보고서 - 음성 채팅 중재.*
[6] Activision. (n.d.). *콜 오브 듀티 음성 채팅 중재 FAQ.* Activision 지원.

ToxMod의 핵심 역할은 음성 채팅을 지속적으로 모니터링하면서 유해 발언의 위험도를 판단하고, 그 결과를 바탕으로 경고나 채팅 제한, 계정 제재 같은 후속 조치가 이루어질 수 있게 지원하는 데 있다. 시스템은 분석에 필요 없는 침묵이나 배경 소음은 걸러내고, 관련성 높은 발화를 중심으로 처리한다. 또 대규모 게임 환경에서도 여러 음성 채팅을 동시에 관리할 수 있게 설계되었다. 이런 방식으로 운영자는 방대한 음성 데이터를 효율적으로 관리할 수 있고, 커뮤니티 안에서 유해 행위에 더 체계적으로 대응할 수 있다.

2. 기술적 특성 및 데이터 처리 과정

게임을 하다 보면 플레이어들의 음성 데이터가 계속 생성되는데, 이 시스템은 그 음성 데이터를 받아 여러 단계를 거쳐 처리하고 분석하는 방식으로 작동한다.

먼저, 게임 내에서 수집된 음성 채팅을 음성 인식 기술로 바로 텍스트로 변환한다. 이 과정에서는 대화와 상관없는 침묵이나 배경 소음은 미리 걸러내고, 의미 있는 말만 남긴다. 이렇게 정제된 텍스트 데이터가 다음 분석 단계에 사용된다. 분석 단계에서는 단순히 욕설 키워드만 찾는 것이 아니라, 머신러닝 기반의 자연어 처리와 감정 분석 모델이 함께 사용된다. 이 모델은 단어 자체뿐 아니라 말투, 감정, 목소리의 느낌, 그리고 대화의 맥락까지 두루 고려한다. 그래서 단순한 장난이나 농담, 혹은 실제 공격적이거나 괴롭힘으로 이어질 수 있는 발화도 구분할 수 있다. 이런 방식은 말 한두 마디만 보고 잘못 판단할 수 있는 경우를 줄이기 위해 도입된 기술적 요소이다.

ToxMod는 각 발화가 얼마나 유해한지, 어떤 유형인지 평가해서 위험 수준을 평가한다. 이 결과는 운영자가 참고할 수 있도록 음성 검토 도구로 전달되고, 문제가 있다고 판단되는 발화의 맥락과 추가 정보도 함께 제공한다. 덕분에 운영 인력이 많지 않은 곳에서도 동시에 수많은 음성 채팅을 한눈에 모니터링하고 관리할 수 있게 설계되어 있다. 또한, ToxMod는 여러 언어를 지원하고, 다양한 나라와 문화권의 이용자가 모인 게임 환경에서도 쓸 수 있도록 만들었다. 분석 과정에서는 억양이나 발음, 비 원어민이 말할 때 나타나는 특징도 반영될 수 있도록 꾸준히 학습하고 있다. 이런 기술 구조 덕분에 ToxMod는 대규모 환경에서도 실시간 음성 데이터를 자동으로 관리할 수 있는 중재 시스템 역할을 한다.

3. 주요 이해관계자 분석

ToxMod는 개발사와 운영 주체뿐 아니라, 게임 이용자, 커뮤니티, 규제 기관, 시민사회 등 다양한 이해관계자에게 서로 다른 형태로 영향을 끼친다. 특히 인공지능이 게임 내에서 직접적으로 중재에 개입하면서, 그 설계와 판단 구조 자체가 이용자가 느끼는 경험과 신뢰 형성에 중요한 역할을 한다.[7]

먼저 Activision과 Modulate 같은 개발 및 운영사는 ToxMod의 설계, 운영 방식, 제재 기준, 데이터 수집 및 처리 방침 등 시스템의 핵심적인 요소를 결정하는 주체이다. 이들이 마련하는 기술적 기준은 플레이어의 실제 게임 경험에 직접적 영향을 미치며, 대규모 음성 데이터를 실시간으로 처리하고 중재할 수 있는 기반을 만든다. 하지만 시스템 운영 중 오탐이나 과도한 제재가 발생할 경우, 이런 문제는 기업의 사회적 이미지나 신뢰도에도 영향을 줄 수밖에 없다.

[7] Sparrow et al.(2024). *Towards ethical AI moderation in multiplayer games*. Proceedings of the ACM on Human-Computer Interaction, 344(8), 1-30.

게임 이용자, 즉 플레이어도 중요한 이해관계자이다. 플레이 과정에서 쌓이는 음성 대화, 신고 이력, 이용 패턴 등이 ToxMod 의 운영과 학습에 간접적으로 쓰인다. 이용자는 자신의 음성 채팅이 AI 판단의 대상이 되고, 이에 따라 경고나 제재를 받기도 한다. 이 때문에 일부는 불이익을 겪을 수 있지만, 반대로 혐오 발언이나 괴롭힘에 노출된 이용자들은 보호 효과를 기대하게 된다. 같은 시스템이지만 이용자마다 경험과 영향은 다르게 나타날 수 있는 것이다.[89] 특히 온라인 멀티플레이 환경에는 아동·청소년 이용자도 다수 포함되어 있어, 혐오 발언 노출에 따른 심리적 피해 가능성이 상대적으로 크다는 점에서 보호 필요성이 더욱 크다.[10]

게임 커뮤니티, 스트리머, e 스포츠 종사자들도 제외할 수 없다. 이들은 AI 중재의 실제 사례와 평가를 공유하며, 이로 인해 커뮤니티에서 해당 기술을 얼마나 신뢰하고 받아들일지가 달라진다. 또 실시간 음성 중재 및 제재는 방송 콘텐츠나 커뮤니티 활동에도 일정한 제약으로 작용할 수 있어서, 게임 문화와 표현 환경에도 영향을 미친다.[11] 규제 기관이나 정책 관련 단체는 개인정보 보호, 표현의 자유, 청소년 보호와 관련된 기준을 제시하여 기업의 기술 운영 방향에 영향을 준다. AI 음성 모더레이션이 널리 도입되면서 제재 권한과 책임 소재를 두고 사회적 논의도 점점 늘어나고 있으며, 이런 변화는 정책적 검토와 새로운 규제 논의로 이어질 수 있다.

마지막으로 AI 윤리 연구자와 관련 시민단체는 프라이버시, 공정성, 투명성, 책임성 등의 측면에서 평가 기준을 제시하고, 기업 정책이나 운영 방식에 대한 사회적 논의를 촉진한다. 실제로 이들은 기술 적용 사례를 분석해 이슈를 공론화하면서 AI 기반 모더레이션이 사회에 잘 받아들여질 수 있도록 영향을 미친다. 다만 기업의 정보 공개 수준이나 대응 방식에 따라 논의의 신뢰와 범위에는 차이가 있을 수 있다.[12]

Ⅲ. 평가 방법·및 자료

1. 평가 방법 및 절차

본 평가는 실제 시스템을 직접 테스트하거나 이용자를 대상으로 설문이나 인터뷰를 진행하지 않았다. 대신 공식 문서와 신뢰할 만한 2 차 자료를 중심으로 시스템의 설계, 운영 방식, 적용 맥락을 들여다보았다. 평가는 몇 가지 단계로 진행되었다. 우선, 시스템의 주요 기능과 운영 구조를 파악하기 위해 개발사와 운영사가 공개한 공식 자료, 서비스 안내, FAQ, 사례 보고서 등을 수집해 검토하였다. 이를 통해 음성 데이터가 어떻게 수집되고 처리되는지, 제재가 자동으로 어떤 구조로 이루어지는지, 그리고 인간 감독자가 어느 정도 개입하는지 등 시스템의 전반적 특성을 정리하였다.

이후 조사한 시스템 개요와 기술적 특성을 바탕으로, 온라인 게임 환경에서 해당 시스템이 이용자와 커뮤니티에 어떤 영향을 줄 수 있을지 살펴보았다. 이때 게임 내 음성 채팅의 특성과 대규모 실시간 운영이라는 환경을 고려해 분석 범위를 설정하였다. 윤리적 영향 분석 단계에서는 강의에서 다룬 '신뢰할 수 있는 AI'의 세부 원칙을 평가 기준으로 삼아, 이 시스템이 사회적·윤리적으로 어떤 쟁점을 낳을 수 있는지 질적으로

[8] 김미선, 이도영, 이종원. (2019). *온라인 게임 내 혐오표현과 게임문화 개선에 대한 연구*. 한국컴퓨터정보학회, 27(2), 299-302.
[9] 국가인권위원회. (2021). *온라인 혐오표현 인식조사*. 국가인권위원회.
[10] 이창호 외. (2014). *청소년의 생성형 AI 이용실태 및 리터러시 증진방안 연구*. (연구보고 24-기본 02). 한국청소년정책연구원.
[11] Kowert & Woodwell. (2022). *Prevalence of offensive behaviors in voice chat*. Take This & Modulate report.
[12] Trithara, D. (2024). *Agents of platform governance: Analyzing U.S. civil society's role in contesting online content moderation*. Telecommunications Policy

분석했다. 정량적 성능 평가나 기술 검증이 아닌 윤리 원칙에 기반한 질적 분석에 초점을 맞췄으며, 특히 시스템의 운영과 사용 단계에서 드러날 수 있는 윤리적 영향을 중심으로 살펴보았다.

2. 활용 자료(내부·외부)

ToxMod의 구조와 윤리적 영향을 살펴보기 위해서는 Activision과 Modulate가 공개한 공식 문서, FAQ, 사례 보고서와 같은 내부 자료와 함께, 언론 기사, 학술 논문, 정책 보고서 등 외부 자료도 참고했다. 내부 자료를 통해서는 음성 데이터가 어떻게 처리되는지, 자동 제재는 어떤 원칙 아래 이루어지는지, 또 실제 운영 방식과 성과는 어떤지 파악하였다. 외부 자료에서는 온라인 게임 안에서 일어나는 혐오 표현과 AI 기반 음성 중재에 대한 사회적·윤리적 논의가 어떻게 이루어지는지 살펴보았다. 이런 내용을 모두 종합해 기술적인 운영 구조는 물론 사회적 맥락까지 함께 고려하며 평가를 진행하였다.

Ⅳ. 평가 내용

1. 적용 윤리 원칙 개요

본 평가는 온라인 게임 환경에서 ToxMod 음성 중재 AI가 이용자에게 어떤 윤리적 영향을 끼치는지 살펴보기 위해, 강의에서 다룬 '신뢰할 수 있는 AI'의 세 가지 주요 원칙, 즉 프라이버시와 데이터 거버넌스, 공정성, 투명성을 중심으로 진행하였다.[13] 이 세 기준은 실시간 음성 데이터 처리와 자동화된 제재가 결합된 AI 중재 시스템의 본질을 가장 잘 보여주는 핵심 요소로 보았다. 이 세 가지 윤리 원칙은 서로 독립적이면서도 밀접하게 연결되어 있다. 이어지는 장에서는 이 원칙들을 바탕으로 ToxMod의 윤리적 영향과 쟁점을 좀 더 구체적으로 분석할 예정이다.

2. 윤리 원칙별 분석

2.1. 프라이버시 및 데이터 거버넌스

프라이버시와 데이터 거버넌스 원칙은 ToxMod가 이용자의 음성 데이터를 실시간으로 수집하고 분석한 뒤, 보관하거나 폐기하는 전 과정에서 정보주체의 권리가 어떻게 지켜지는지 살펴보는 기준이다. 음성 데이터는 개인을 식별할 수 있는 민감한 정보에 속하기 때문에, 항시적인 모니터링 구조는 감시나 사생활 침해에 대한 우려를 키울 수 있다. 이런 점을 고려해, 이번 평가는 데이터 수집의 적법성과 최소화, 보안 조치, 그리고 정보주체의 권리 보장이 실제로 이루어지고 있는지에 초점을 맞췄다.

2.1.1. 프라이버시 및 데이터 거버넌스 원칙 선정 이유

ToxMod처럼 실시간 음성 중재 AI가 도입된 환경에서 '프라이버시와 데이터 거버넌스'는 서비스 신뢰도를 좌우하는 가장 중요한 가치이다.

그 첫 번째 이유는 다루는 데이터 자체가 매우 민감하기 때문이다. 음성 데이터에는 화자의 신원, 성별, 건강 상태 같은 개인 정보가 고스란히 담겨 있다. 실시간 분석이 이루어질 경우, 자칫하면 감청이나 생체 정보의 무단 수집으로 오해받기 쉽다. 그래서 법적, 윤리적으로 철저하게 관리할 수 있는 체계가 반드시 필요하다.

두 번째는 비정형 데이터의 특성 때문이다. 음성 채팅에서는 사용자 의도와 상관없이 주변 소리나 다른 사람의 목소리까지 녹음될 수 있다. 의도치 않은 정보가 남지 않도록, 수집과 저장 단계에서 정교하게 선별하고 즉각 파기하는 거버넌스 시스템이 중요해진다.

[13] 김희재. (2025). *데이터 윤리와 보안* [10주차 강의자료 (PPT)]. 서울여자대학교.

마지막으로, AI가 항상 감시하고 있다는 점도 문제이다. 유해 발언을 실시간으로 잡아내는 시스템은 사용자에게 늘 누군가 지켜보고 있다는 불쾌감을 줄 수 있다. 이런 불신을 해소하려면 데이터가 어떻게 처리되고, 언제 삭제되는지 투명하게 공개하여 신뢰를 쌓아야 한다.

2.1.2. 프라이버시 및 데이터 거버넌스 평가 기준 및 방법

본 평가는 한국의 「개인정보 영향평가 수행안내서(2025)」 및 「AI 개인정보보호 자율점검표」에서 제시하는 평가 항목을 기준으로 수행하되, ToxMod 시스템의 글로벌 서비스 특성을 고려하여 EU(GDPR, AI 법) 및 미국(COPPA, CPRA)의 법적 요구사항을 평가 기준으로 활용하여 분석하였다.[14][15][16][17]

이는 기업의 공식 정책 문서와 글로벌 법적 기준을 핵심 자료로 활용한다.

① Activision 이용 약관 및 FAQ: 음성 데이터 수집의 법적 근거, 보유 기간, 거부권 행사 현황 등 운영 현황 파악.[18]

② Modulate 기술 문서: AI 학습 시 데이터의 비식별화, 서버 저장 시 암호화 적용 여부 등 기술적 안전성 검증.[19][20]

③ 글로벌 프라이버시 규제 가이드라인: EU GDPR(민감정보 동의), 미국 COPPA(아동 보호), 국내 「개인정보 영향평가 수행안내서」(파기 및 안전조치) 등 평가 기준으로 활용.

2.1.3. 프라이버시 및 데이터 거버넌스 세부 평가 결과

평가 영역	평가 기준	평가
수집 및 적법성	1. 개인정보를 수집하는 경우 정보주체의 동의를 받거나, 법령 등에 따라 적법하게 수집하도록 계획하고 있는가?	충족(○)
	2. 민감정보(생체인식정보 등)를 처리하는 경우 별도로 구분하여 동의를 받거나, 법령에 따라 적법하게 처리하고 있는가?	부분충족(△)
	3. 만 14 세 미만 아동의 개인정보 수집 시 법정대리인의 동의를 받고, 동의 여부를 확인하고 있는가?	미흡(X)
데이터 최소화 및 파기	4. 개인정보의 보유 목적이 달성되었거나(무혐의 등) 보유 기간이 경과되었을 때 지체 없이 파기되도록 계획하고 있는가?	충족(○)
	5. AI 학습데이터의 보유기간을 정하고, 학습·개발 완료 등 불필요하게 되었을 때에는 지체 없이 파기하고 있는가?	충족(○)
안전성 및 거버넌스	6. AI 학습·개발을 위해 개인정보를 수집·이용하는 경우, 가명/익명처리 등 적법 요건을 준수하고 있는가?	충족(○)
	7. 인증정보, 고유식별정보 등 중요 개인정보(음성 원본 등)를 저장하는 경우 안전한 방식으로 암호화하고 있는가?	부분충족(△)
정보주체 및 권리보장	8. 개인정보 처리 정지(수집 거부) 등 정보주체의 권리보장과 요구에 대한 처리절차를 수립하여 실시하고 있는가?	충족(○)

<표 1> ToxMod 프라이버시 및 데이터 거버넌스 영향 평가

[14] 개인정보보호위원회. (2025). *개인정보 영향평가 수행안내서* (2025. 10. 개정).
[15] 개인정보보호위원회. (2021). *인공지능(AI) 개인정보보호 자율점검표* (2021. 5. 제정).
[16] 개인정보보호위원회. (2022). *우리 기업을 위한 EU 일반 개인정보보호법(GDPR) 가이드북* (2022. 12. 개정).
[17] 세계법제정보센터. (n.d.). *아동의 온라인 개인정보 보호법(Children's Online Privacy Protection Act)*.
[18] Activision. (n.d.). *개인정보 보호정책*.
[19] Modulate. (n.d.). *Privacy Policy*.
[20] Modulate. (n.d.). *Privacy and Data Management*.

① 수집 및 적법성

• [평가 기준 1] 수집의 적법성 (충족)
Activision 은 이용 약관 및 개인정보처리방침을 통해 서비스 이용 시 음성 채팅이 모니터링 및 녹음될 수 있음을 명시하고, 게임 이용 시 이에 동의한 것으로 간주하여 수집의 계약적 근거를 확보하고 있다.

• [평가 기준 2] 민감정보 별도 동의 (부분 충족)
음성 데이터는 개인을 식별할 수 있는 생체인식정보에 해당할 수 있으나, 이에 대해 별도의 명시적인 선택 동의 절차를 거치지 않고 이용 약관에 포함하여 일괄 동의를 받고 있다. 이는 GDPR 제 9 조 및 국내법상 민감정보 처리 요건 위반 소지가 있으며, 최근 미국 일리노이주(BIPA) 등에서 이와 관련된 법적 쟁점이 제기되고 있다.[21]
  - 실증적 사례: 미국 일리노이주에서 액티비전이 음성 채팅 중재 과정에서 생체정보를 수집하면서 별도의 동의를 받지 않아 BIPA 관련 법적 문제에 휘말렸다. 이런 사례는 ToxMod 가 안고 있는 데이터 거버넌스 측면의 위험성을 잘 보여준다.[22]

• [평가 기준 3] 아동 보호 (미흡)
약관상 13 세 미만 이용을 금지하고 있으나, 실제 AI 가 음성 분석 중 아동의 목소리를 감지했을 때 이를 즉시 차단하거나 부모 동의를 요구하는 기술적 보호조치에 대한 명시가 부족하다. Modulate 의 정책은 고객사에게 동의 획득 책임을 부여하고 있어, 실제 운영 단계에서의 아동 보호 강제력이 불확실하다.[23]

② 데이터 최소화 및 파기

• [평가 기준 4] 목적 달성 후 파기 (충족)
ToxMod 운영 정책(FAQ)에 따르면, 유해성이 감지되지 않은 데이터는 분석 직후 또는 통상 24 시간 이내에 파기되며, 유해성이 확인되어 제재가 필요한 데이터만 이의 제기 대응을 위해 일정 기간 보관된다. 이는 데이터 최소화 원칙을 충실히 이행하는 정책으로 평가된다.

• [평가 기준 5] AI 학습데이터 관리 (충족)
개발사 Modulate 의 개인정보처리방침에 따르면, AI 모델의 학습 및 튜닝을 위해 사용되는 데이터는 익명화 처리 후 최대 10 년간 보관하며, 이후 삭제된다. 이는 불필요한 원본 데이터의 축적을 방지하고 학습 목적에 필요한 기간만큼만 보유하는 합리적인 거버넌스로 판단된다.

③ 안전성 및 거버넌스

• [평가 기준 6] 가명/익명처리 (충족)
AI 학습 및 서비스 개선을 위해 데이터를 활용할 때, 개인을 식별할 수 없도록 랜덤 ID 를 부여하는 등 비식별화 조치를 수행하고 있음을 기술 문서에 명시하고 있다.

• [평가 기준 7] 암호화 저장 (부분충족)
개발사 Modulate 는 AWS VPC 내에서 저장 시 암호화를 적용한다고 명시하고 있으나, 실제 서비스를 제공하는 Activision 의 이용자 대상 정책 문서에서는 녹음된 음성 파일 자체의 암호화 여부가 구체적으로 안내되지 않아 투명성이 다소 부족하다고 판단된다.

---

[21] 국회도서관 의회법률정보포털. (n.d.). *미국 일리노이주 생체정보 개인정보 보호법 (BIPA)*.
[22] McKenzie. (2024). *Activision Uses AI to Ban Racial Slurs in Call of Duty Voice Chats*. 80 Level.
[23] Activision. (n.d.). *청소년용 개인정보 보호정책*.

④ 정보주체 권리보장

• [평가 기준 8] 처리 정지 및 거부 (충족)

이용자는 게임 내 설정에서 '음성 채팅 비활성화' 기능을 통해 언제든지 자신의 음성 데이터 수집 및 분석을 원천적으로 거부할 수 있다. 이는 정보주체의 자기 결정권을 실질적으로 보장하는 조치이다.

2.1.4. 프라이버시 및 데이터 거버넌스 개선 방안

앞서 실시한 영향평가에 따르면, ToxMod 는 민감정보 처리의 적법성, 아동 보호 조치, 그리고 보안 조치의 투명성에서 빠른 개선이 필요한 것으로 나타났다. 이에 대해 구체적인 개선 방안을 다음과 같이 제안한다.

① 민감정보(음성) 처리에 대한 별도 동의 절차 도입

음성 데이터는 생체인식정보, 즉 민감정보에 해당하지만, 현재는 이용 약관에 포함해 포괄적으로 동의를 받고 있어 국내법(제 23 조)과 GDPR(제 9 조)을 위반할 소지가 크다. 이는 게임을 처음 실행하거나 음성 채팅 기능을 시작할 때, 이용 약관과는 별도의 '음성 데이터 수집 및 분석 동의' 안내창을 띄워 이용자가 직접 선택해 동의할 수 있도록 해야 한다.[24]

② 아동 보호를 위한 기술적 차단과 보호자 동의 강화

정책상 만 13 세 미만의 이용을 금지하고 있지만, 실제로 AI 가 아동의 음성을 감지했을 때 즉시 차단하거나 부모 동의를 요구하는 구체적인 기술적 조치가 부족하다. 이를 위해 AI 모델이 아동의 목소리를 인식하면 해당 기능을 일시 중단하는 'AI 기반 연령 탐지 및 차단' 로직을 적용해야 한다. 이후 기능을 다시 사용하려면 법정대리인 인증 등 추가 본인 확인 절차가 도입되어야 한다.

③ 음성 데이터 저장 시 암호화 적용과 투명한 공개

데이터가 전송되는 과정에서 보안은 확보되어 있지만, 서버에 저장되는 음성 녹음 파일 자체가 암호화되는지는 분명하지 않다. 만약 이 파일이 유출될 경우, 민감한 정보가 심각하게 노출될 수 있다. 이를 위해서는 저장되는 모든 음성 녹음 파일은 안전한 암호화 기술을 적용해 보관해야 하며, '개인정보처리방침'과 같은 안내문에도 "수집된 음성 데이터는 암호화되어 안전하게 저장됩니다"라는 내용을 명확히 밝혀야 한다. 이렇게 해야 보안 관리의 투명성도 함께 높아질 것이다.

2.2. 공정성

공정성 원칙은 AI 가 음성 발화를 분석하고 제재 여부를 결정하는 과정에서, 특정 집단이나 말투가 불이익을 당하지 않는지 확인하는 데 쓰인다. 억양이나 사투리, 비원어민의 발음, 문화적 맥락의 차이 등은 오탐이나 편향된 결과를 낳을 수 있기 때문에, 자동화된 중재 시스템에서는 특히 더 주의가 필요하다. 본 평가는 ToxMod 가 이런 편향 가능성을 어떻게 관리하고 있는지 공정성 관점에서 따져본다.

2.2.1. 공정성 원칙 선정 이유

사람이 직접 구현한 대로 동작하는 기존의 소프트웨어와는 달리, AI 의 소프트웨어는 학습한 데이터에 따라 사고하고 행동한다. 즉, 규칙에 따라 같은 상황에서 항상 같은 동작을 하는 기존 소프트웨어와는 다르게, 학습된 데이터가 달라지면 같은 상황에서도 다른 동작을 할 수 있다. 이로 인해 AI 는 다양한 공정성 문제를 일으킬 수 있다.

[24] 국가법령정보센터. (n.d.). *개인정보 보호법 조문정보*.

예를 들어, 학습 데이터에 편향이 내제된 경우에는 성차별이나 인종차별 등의 윤리적인 문제가 생길 수 있다. 실제로 아마존에서 채용 의사 결정에 도움을 주는 알고리즘을 개발하고, 그 알고리즘을 학습시키기 위해 근 10년 간의 이력 데이터를 활용했다. 그러나 데이터에 사용된 10년은 남성이 IT 업계의 중심에 서 있던 시대였고, 그 결과 아마존 알고리즘은 여성 지원자에 대해 부당한 판단을 내렸다. 강의에서도 언급되었던, 흑인 피고인에게 높은 위험 점수를 매기는 편향 알고리즘이 재범 위험 예측에 사용 판결에 영향을 준 미국 몇몇 주의 형사사법제도의 사례도 예로 들 수 있다.

특히 ToxMod와 같은 실시간 음성 대화를 분석해 유해 발언을 탐지하는 AI는 공정성이 필수 원칙이다. 음성 데이터는 억양이나 언어·문화적 표현 등 개인적 차이가 크게 나타나는 영역이므로, AI가 이를 정확히 해석하지 못한다면 특정 플레이어에게 불리한 결과가 나타날 수 있기 때문이다. 따라서 ToxMod가 모든 사용자에게 동등한 기준을 적용하고 판단하는지를 평가하기 위해 공정성을 핵심 원칙으로 선정하였다.

2.2.2. 공정성 평가 기준 및 방법

ToxMod에 대한 공정성 평가는 국내·국제법에서 제시하는 AI 공정성의 법적·윤리적 원칙을 토대로 한다. 국내와 국제 규범을 둘 다 살펴본 이유는 EU는 기술과 편향 방면, 국내법은 정책·사회적 방면으로 서로 다른 관점을 가지고 있기 때문이다. 먼저 국내 규범으로는 내년에 시행이 예정된 「인공지능 발전과 신뢰 기반 조성 등에 관한 기본법」을 참고했다. 이 법률에서는 국가가 인공지능의 공정성·투명성·책임성·안전성 확보를 위하여 신뢰 기반을 조성해야 한다고 명시한다.[25]

국제 규범인 EU AI Act 또한 공정성을 핵심 원칙으로 규정한다. 특히 데이터 편향이나 기술의 부정확성 등으로 인해 AI가 구조적 차별을 일으킬 수 있다고 지적하며, 대표성 있는 데이터 확보와 지속적인 모니터링을 강조한다.[26][27]

이처럼 공정성 원칙에서 국내법은 이용자 보호와 형평성을, EU 법은 데이터 품질 및 편향 제거의 기술적 요구를 중요시한다. 이 두 규범을 근거로 삼아 ToxMod의 데이터 구성과 판단 및 제재 과정이 공정성 원칙을 충분히 반영하고 있는가를 살펴보았다.

2.2.3. 공정성 세부 평가 결과

① 데이터 공정성

데이터 공정성은 AI 모델 학습에 활용되는 데이터가 다양한 문화 및 언어 사용자의 데이터를 충분히 포함하고 있는가를 평가한다. 데이터는 모델 학습의 기반이 되므로 이 단계에서 편향이 발생한다면 모델의 편향으로 이어져, 해당 평가는 공정성 평가의 가장 기본이다. 데이터 공정성 평가는 다양한 언어·억양·표현이 데이터에 충분히 포함됐는지, 특정 집단이 과도하게 포함되거나 배제되지는 않았는지를 기준으로 한다.

② 모델 판단의 공정성

모델 판단의 공정성은 ToxMod가 사용자의 성별이나 인종, 문화적·언어적 배경을 고려하지 않고 일관적인 기준으로 판단하는가를 평가한다. 이는 AI가 전세계 사용자에게 공정하게 적용될 수 있는지를 평가하는 핵심적인 기준이다. 모델 판단의 공정성 평가는 모델이 판단할 때 의도와 맥락을 고려하는지, 오탐률이 특정 집단에서 과도하게 발생하지는 않는지를 기준으로 한다.

---

[25] 인공지능 발전과 신뢰 기반 조성 등에 관한 기본법, 법률 제20676호 (2025).

[26] European Parliament and Council. (2024). *Regulation (EU) 2024/1689 (Artificial Intelligence Act).*

[27] 한국정보통신기술협회. (2024). *2024 신뢰할 수 있는 인공지능 개발안내서 - 일반 분야.*

③ 제재 결과의 공정성

제재 결과의 공정성은 모델의 오탐으로 인해 잘못된 조치가 발생했을 때, 그 영향이 특정 집단에게 편향되지는 않는가를 평가한다. 제재 결과에 대한 공정성은 시스템 사용자가 직접 체감할 수 있으므로 가장 민감한 평가 영역이라고 할 수 있다. 제재 결과의 공정성 평가는 비슷한 발화를 했을 때 사용자가 속한 집단에 따라 제재의 강도가 차이 나는지, 초기의 오탐이 누적될 시 특정 집단의 사용자에게 불이익이 과도하게 적용되지는 않는지를 기준으로 한다.

④ 절차의 공정성

절차의 공정성은 AI 모델의 판단 이후, 사용자의 권리 보장 체계가 제대로 갖춰져 있는가를 평가하는 영역이다. 해당 평가는 시스템의 기술 정확성과는 별개로 사용자의 신뢰를 형성하는데 기여한다. 절차의 공정성 평가는 제재 사유 및 판단 기준을 사전에 명확히 설명했는지, 판단에 대한 이의를 제기할 수 있는지, 오판에 의한 불이익을 받았을 때 이를 구제할 수 있는지를 기준으로 한다.

평가 영역	평가 기준	평가 내용	평가
데이터 공정성	1. 데이터 대표성 여부	다양한 억양·발화 특성·비 원어민 영어가 균형적으로 포함되었는가?	부분 충족 (△)
	2. 데이터 편향 식별·제거 절차 존재	특정 집단 음성이 과소/과대 대표되는지 점검하는 체계가 있는가?	부분 충족 (△)
모델 판단의 공정성	3. 맥락 기반 판단 능력	비속어·격한 발화를 문맥 없이 단순 공격성으로 분류하지 않는가?	부분 충족 (△)
	4. 공격성 판단의 일관성	동일 상황·유사 문맥에서 동일한 판단이루어지는가?	부분 충족 (△)
제재 결과의 공정성	5. 제재 기준의 형평성	동일 수준 발화에 대해 사용자 집단 간 제재 강도 차이가 없는가?	충족 (○)
	6. 누적 제재의 공정성	잘못된 판단이 누적되어 특정 사용자에게 불리하게 작용하지 않는가?	미충족 (X)
절차의 공정성	7. 설명 가능성	어떤 발화가 문제가 되었는지 사용자에게 설명이 제공되는가?	미충족 (X)
	8. 이의제기 절차	제재에 대한 이의제기가 가능하며 실질적으로 처리되는가?	충족 (○)
	9. 시정·구제 체계	잘못된 제재가 빠르게 취소되거나 수정되는 체계가 있는가?	부분 충족 (△)

<표 3> ToxMod 공정성 영향 평가

해당 표는 앞서 나온 평가 기준을 바탕으로 하되, 실제로 평가 가능한 문항으로 구체화하기 위하여 「TTA 신뢰할 수 있는 인공지능 개발안내서」와 「AI 개인정보보호 자율 점검표」를 참고하고, ToxMod 기술 보고서에 나온 내용에 의거해 평가했다.[28]

① 데이터 공정성

• [평가 기준 1] 데이터 대표성 여부 (부분 충족)

ToxMod의 데이터 학습은 기본적으로 영어 음성 데이터를 중심으로 진행되고 있고, 따라서 비 원어민이나 지역 억양이 강한 플레이어들의 발화 데이터가 충분히 학습되었다고 보기는 힘들다. 이로 인해 생기는 데이터 편향은 특정 발음이나 억양이 더 부정적으로 인식될 가능성이 있으므로 부분 충족으로 평가했다.

[28] Modulate. (n.d.). *ToxMod 기술 보고서*.

• [평가 기준 2] 데이터 편향 식별·제거 절차 존재 (부분 충족)
ToxMod는 전체 음성을 분석하는 구조가 아닌 유해 신호가 감지된 대화만을 수집해 심층 분석하는 triage 모델을 사용한다. 이는 설계상 anger, distress 같은 특정 음향을 공격성의 초기 신호로 감지하도록 되어있어, 데이터 선별부터 편향이 발생할 수 있다. 그러나 이를 식별하고 교정하기 위한 절차가 소개되지 않아 부분 충족으로 평가했다.

② 모델 판단의 공정성

• [평가 기준 3] 맥락 기반 판단 능력 (부분 충족)
보고서에서 심층 분석 모델은 단어뿐 아니라 슬랭이나 문화적 규범, 플레이어 간 농담 등의 상호작용을 이해한다고 쓰여있다. 이는 기존 필터링 시스템보다 공정성이 반영되었지만, 초기에 오탐되어 잘못 걸러진 발화가 있는 경우 후에 정정할 기회를 얻지 못하므로 부분 충족으로 평가했다.

• [평가 기준 4] 공격성 판단의 일관성 (충족)
문서 내에서는 운영자가 전체 맥락을 확인하면 행동 악성 여부를 일관된 방식으로 판단할 수 있도록 대화 흐름 전체를 제공한다고 언급한다. 운영자에게 전체적인 맥락을 제공하는 구조는 단편적인 단어 기반 필터보다 훨씬 일관되고 공정한 판단 구조이므로 충족으로 평가했다.

③ 제재 결과의 공정성

• [평가 기준 5] 제재 기준의 형평성 (부분 충족)
ToxMod는 실시간 대응인 proative moderation을 사용하고 있다. 문제가 감지될 때 즉시 개입하는 것은 좋은 점이지만, 초기 triage 모델이 특정 집단의 사용자 발화를 과도하게 공격적이라 판단했을 경우 동일 수준의 발화일지라도 집단에 따라 제재가 불공정하게 적용될 수 있으므로 부분 충족으로 평가했다.

• [평가 기준 6] 누적 제재의 공정성 (미충족)
proactive moderation은 반복적인 공격적 발화를 신속히 차단한다. 그러나 오탐 초기화나 보정 누적 로직 등의 공정성 보완 장치는 언급된 바가 없다. 사용자에게 제재가 누적되는 것은 장기적으로 특정 집단이나 사용자에게 불리하게 적용될 가능성이 있으므로 미충족으로 평가했다.

④ 절차의 공정성

• [평가 기준 7] 설명 가능성 (미충족)
문서에서는 ToxMod가 운영자에게 상황 및 발화의 맥락을 제공한다고 언급하고 있으나 사용자에게 제재 사유에 대해 설명하는 기능은 찾아볼 수 없다. 이는 사용자는 자신의 발화가 문제로 판단된 이유를 알 수 없다는 뜻이므로 미충족으로 평가했다.

• [평가 기준 8] 이의제기 절차 (충족)
ToxMod는 운영자의 판단을 돕는 보조 시스템인 검토 기능을 갖추고 있다. 사용자가 제재에 반발할 경우, 운영자는 제공된 상황 및 발화 맥락을 바탕으로 제재의 합리성을 검토할 수 있어 이의제기 절차가 원활하리라 판단되므로 충족으로 평가했다.

• [평가 기준 9] 시정·구제 체계 (부분 충족)
ToxMod는 운영자가 상황을 검토하고 조치할 수 있도록 맥락을 전달하며, 이 과정에서 운영자와의 상호작용 기반 피드백 루프가 존재한다. 그러나 AI가 잘못된 판단을 자동으로 수정하거나 철회하는 기능이나 오탐을 초기화하는 기능은 명시되어 있지 않으므로 부분 충족으로 평가했다.

2.2.4. 공정성 개선 방안

ToxMod의 공정성을 강화하기 위해서는 각 영역에 걸쳐 개선 방안이 필요하다. 먼저 데이터 측면에서는, 보다 다양한 지역 및 언어권과 문화권에 속한 사람들의 음성 데이터를 수집해 게임 플레이어의 단순한 흥분 발화나 감정 표현이 공격적인 발언으로 오탐되지 않도록 대표성을 확보해야 한다.[29]

모델 측면에서는, 분석 단계에서 오탐률을 낮추기 위한 개선을 실시해야 한다. 현재의 맥락 기반 분석은 유지하되 고음, 비명 및 함성 등이 공격적인 발화로 분류되지 않도록 다중 특징 비교나 집단별 성능 모니터링을 도입할 필요가 있다.[30][31]

제재 측면에서는, 실시간 제재 체계를 유지하면서도 잘못된 제재가 누적되지 않도록 triage 모델에서 감지된 발화가 곧바로 제재로 이어지는 일이 없도록 해야 한다. 예를 들어 경고 → 운영자의 실시간 검토 → 제재 등의 단계적 절차를 만들어야 하고, 오탐으로 인한 반복적인 제재가 특정 집단의 플레이어에게 불리하게 작용하지는 않는지에 대한 모니터링도 필요하다.

절차 측면에서는, 제재 시 플레이어에게 사유를 명확히 전달하고 이의제기 절차의 접근성을 높여야 한다. 해당 발화의 문제 유형, 판단 기준 등을 자세히 안내할 수 있는 설명 시스템을 구축하고, 오탐이 확인되면 신속히 철회하는 프로세스를 마련할 필요가 있다.

또한 이용자별 발화량 차이나 새롭게 등장하는 혐오 표현의 빠른 변화는 모델 학습의 시차로 인해 특정 이용자에게 불리한 결과를 초래할 가능성이 있어, 지속적인 업데이트와 검증이 요구된다.

2.3. 투명성

투명성 원칙은 AI가 내리는 제재가 이용자에게 얼마나 명확하게 설명되는지 평가하는 기준이다. 자동화된 판단 과정에서 제재의 사유와 근거, 이의 제기 절차 등이 충분히 안내되지 않는다면, 이용자는 시스템을 쉽게 신뢰하지 못할 수 있다. 이에 이번 평가는 ToxMod의 운영 방침과 사용자 안내 수준을 중심으로, 의사결정 과정이 얼마나 투명하게 공개되는지 살펴본다.

2.3.1. 투명성 원칙 선정 이유

ToxMod는 AI 기반 음성 중재 시스템으로 게임 이용자의 음성 수집이 불가피하다. 이용자 한 명 한 명의 음성을 수집하는 만큼 개인정보에 대한 불안감이 발생할 수 있다. 이에 따라 AI 시스템의 운영 이유, 데이터의 수집과 범위, 제재 과정 등 시스템에 대한 설명을 투명하게 공개하고 제공하여 신뢰감을 주어야 한다. 따라서 이와 관련된 AI 관련 개인정보보호 6대 원칙 중 하나인 '투명성'에 대해 알고, ToxMod는 투명성을 충분히 실행하고 있는 AI인지 평가할 필요성이 있다.

2.3.2. 투명성 평가 기준 및 방법

EU의 신뢰할 수 있는 AI 윤리 가이드라인을 살펴보면 투명성의 특징으로 사전 고지, 추적 가능성, 설명가능성을 제시했다.[32] ToxMod는 게임 이용자, 특히 그들의 음성을 대상으로 하는 만큼 AI 사용 사실과 개인정보처리방침을 미리 고지하고(사전 고지),

---

[29] 손영화. (2023). *AI 공정성에 관한 연구-차별 없는 AI 사회의 실현-*. Hanyang Law Review, 34(3), 83.
[30] Angwin, J., Larson, J., Mattu, S., & Kirchner, L. (2016). *Machine Bias*. ProPublica.
[31] Dastin, J. (2018). *Amazon scraps secret AI recruiting tool that showed bias against women*. Reuters.
[32] 유럽연합(EU). (n.d.). *인공지능(AI) 윤리 가이드라인*.

제재를 주었다면 그 근거를 제시하여야 한다(설명 가능성). 개발사와 운영사는 그 근거를 제시할 수 있도록 인공지능의 의사결정 과정을 추적할 수 있어야 한다(추적 가능성).

투명성을 평가하는 점검표로는 '개인정보보호위원회의 AI 개인정보보호 자율점검표'와 '신뢰할 수 있는 인공지능 개발 안내서: 일반 분야'을 참고했다.

2.3.3. 투명성 세부 평가 결과

평가 영역	평가 기준	평가
사전 고지	1. 개인정보처리방침에 의무적 수록사항을 포함하였는가?	충족(○)
	2. AI 서비스의 작동방식, 개인정보 활용 프로세스 등을 이해하기 쉽게 설명하고 공개하는가?	충족(○)
설명 가능성	3. 사용자가 모델 추론 결과의 도출 과정을 수용할 수 있도록 근거를 제공하는가?	미흡(X)
	4. AI 기술·서비스의 개인정보 처리에 대한 이용자의 제안(의견수렴), 문의 및 이의 제기 등을 접수·검토·회신하고 개선할 수 있는 업무 및 조직체계를 갖추었는가?	충족(○)
추적 가능성	5. 인공지능 시스템의 의사결정에 대한 추적방안을 수립하였는가?	부분충족(△)

<표 4> ToxMod 투명성 영향 평가

① 사전 고지

- [평가 기준 1] 개인정보처리방침 공개 적정성 (충족)
  Modulate 는 개인정보처리방침을 통해 수집 목적, 처리 범위, 보안 조치, 권리 행사 방법 등 개인정보 처리 시 필수적으로 고지해야 할 사항을 명시하고 있다. 의무적인 사항을 홈페이지와 서비스 사용 전에 제공하기 때문에 투명성을 충족한다고 할 수 있다.
- [평가 기준 2] AI 처리 과정 설명 투명성 (충족)
  Activision 과 Modulate 는 개인 정보 보호 정책과 공식 자료를 통해 AI 기반 음성 중재 시스템의 작동 방식과 문의 경로를 공개하고 있다. FAQ 등을 통해 이용자들이 더 간단하고 명료하게 이해할 수 있도록 설명해 놓았다. 또한, Modulate 에서는 AI 시스템 작동방식을 확인하고 간단하게 작동시켜 볼 수 있다. 다만, 실제 이용자가 확인해야 하는 정보가 Modulate 의 홈페이지에 집중되어 있어 접근성 측면에서는 한계가 존재한다.

② 설명 가능성

- [평가 기준 3] 추론 결과 설명 가능성 (미흡)
  modulate 홈페이지에서 Toxmod In Action 이라는 프로토타입을 통해 시스템의 작동과 추론 방식을 확인할 수 있다.[33] 제재나 페널티를 받게 되는 최소 점수를 설정과 어떤 발언이 혐오 발언인지 예시도 볼 수 있다. 이와 같은 시스템 작동방식을 제재나 페널티의 근거로 제시할 수 있다. 그러나 실제 상황에서는 그 근거가 명확히 제시되지는 확인할 수 없다. Activision 의 FAQ 에 따르면 음성 채널 패널티에 이의제기가 불가능하다고 나와있어, 근거 요구 기회를 제공하지 않아 결과 수용에 한계가 있다.
- [평가 기준 4] 이용자 권리 대응 체계 (충족)
  Activison 에서는 개인정보보호정책에 개인정보보호팀과 개인정보보호정책 부서를

[33] Modulate. (n.d.). *ToxMod In Action*.

명시해놓아 이용자 문의 검토를 하는 업무조직이 있음을 간접적으로 알 수 있다. 국가나 지역별로도 각각 이메일로 권리 행사를 할 수 있도록 해놓았다. Modulate 는 공식 이메일로 정보보호팀에 문의하라고 밝혔다. 이외에도 데이터보호기관(DPA) 등 다양한 데이터 보호 기관에 문의하도록 링크를 걸어놓았다.

③ 추적 가능성

• [평가 기준 5] 의사결정 추적 가능성 (부분 충족)

Activision 의 공식 FAQ 에 따르면 최종 제재 결정은 게임사가 수행하며, AI 의 판단 결과는 보조적으로 활용된다. EU 인공지능 법 제 12 조(기록관리)를 살펴보면 '고위험 인공지능시스템의 의도된 목적에 적합한 해당 시스템의 기능에 대한 추적성을 확보하기 위하여 다음 사항과 관련된 사건의 기록할 수 있는 로깅 기능이 있어야 한다'.[34] 로그, 로깅이란 기술적으로 그 시스템의 수명주기 동안에 사건을 자동으로 기록하는 것이다. Modulate 의 PRIVACY POLICY 의 Autonatically 에서 로그를 자동으로 수집한다고 밝혔으나, 세부 로그 사항이 추상적이며 프로세스별 수집 정보 등의 형식을 자세하게 표시해놓지 않았다.

2.3.4. 투명성 개선 방안

ToxMod 는 전반적으로 투명성을 보장하려고 하지만, 아쉬운 부분도 있다. 그래서 아래와 같은 개선 방안들을 통해 투명성을 더 높일 필요가 있다.

먼저, 판단 기준을 명확하게 공개하고 강화해야 한다. 현재 ToxMod 는 설명 과정에서 결과에 대한 충분한 근거를 제공하지 않아, 이용자들이 답답함을 느끼기 쉽다. 이로 인해 사용자는 문의처를 직접 찾아 연락하고, 답변을 기다리는 불편을 겪어야 하는 상황이 생길 수 있다. 이런 경험이 반복되면 게임에 대한 피로감이 쌓이고, 결국 이용을 중단하게 될 수도 있다. 따라서 어떤 기준과 절차에 따라 제재가 이루어지는지 구체적으로 공개해야 하며, 이용자가 충분히 이해하고 받아들일 수 있도록 만들어야 한다.

두 번째로, AI 시스템이 어떻게 작동하는지 쉽게 설명하는 것도 중요하다. 자신의 음성 데이터가 사용되는 만큼, 그 데이터가 시스템에서 어떻게 활용되는지 각자가 알 권리가 있다. 이를 위해 시스템이 작동하는 방식이나 흐름을 시각적으로 보여주거나, 홈페이지 등에서 손쉽게 확인할 수 있는 경로를 마련하는 등 구체적인 안내가 필요하다.

또 하나는 정기적인 감사의 도입이다. ToxMod 는 음성처럼 민감한 정보를 수집하는 만큼 개인정보 보호와 관리에 각별히 주의를 기울여야 한다. 개인정보가 올바로 관리되고 있는지 주기적으로 점검하고, 그 결과를 담은 투명성 보고서를 꾸준히 공개해야 이용자들이 안심하고 서비스를 이용할 수 있다. 그리고 외부 AI 윤리 기관 등으로부터 정기적으로 시스템이 윤리 기준에 부합하는지 점검을 받는 것도 중요하다. 이렇게 해야만 회사에 대한 신뢰를 높이고, 책임 있는 AI 운영을 이어갈 수 있을 것이다.

3. 윤리적 딜레마 제시

이번 평가에서 드러난 윤리적 딜레마는 게임 이용자 보호를 위해 음성 중재를 강화하려는 시도와, 이용자의 표현의 자유를 보장해야 한다는 고민이 부딪히는 데서

[34] 세계법제정보센터. (2025). *EU 인공지능법*.

비롯된다. ToxMod 음성 중재 인공지능은 게임 내 음성 채팅에서 혐오 발언이나 욕설, 괴롭힘 등 문제되는 표현을 실시간으로 탐지해 제재하는 것이 목적이다. 이런 기능 덕분에 이용자는 어느 정도 보호받을 수 있지만, 동시에 그 과정에서 표현의 자유와 자연스러운 소통 역시 제한될 수밖에 없다. 음성 중재를 적극적으로 적용하면, 혐오 표현이나 공격적인 발언으로부터 이용자를 보호해 보다 쾌적한 게임 환경을 만들 수 있다. 이런 노력은 피해 경험을 줄이고, 사람들이 게임을 오래 즐기게 만들며, 결국에는 게임 커뮤니티의 신뢰도나 게임을 운영하는 주체에 대한 긍정적인 이미지로 이어질 수 있다. 특히 경쟁이 치열한 온라인 게임에서는 이런 보호 시스템이 게임의 전반적인 경험을 지키는 중요한 역할을 한다.

하지만 만약 음성 중재가 자동으로 상시 작동하게 된다면, 이용자는 자신이 늘 감시받고 있다는 생각을 할 수도 있다. 더구나 시스템 오작동이나 오해로 인해 정당한 발언도 제재를 당하면 억울함을 느끼고, 결과적으로 시스템 자체에 불신을 갖게 될 수 있다. 이로 인해 표현의 자유와 발화 자율성이 위축되는 결과가 나타날 수 있는 것이다.

반대로 표현의 자유를 넓게 보장하면, 이용자들은 음성 대화를 통해 더욱 몰입도 높은 소통을 하며 게임을 즐길 수 있다. 이는 협동하거나 경쟁하는 과정에서 자연스러운 대화를 가능하게 하고, 게임의 재미를 높일 수 있는 긍정적인 효과도 가져온다. 그러나 욕설이나 비방 같은 유해한 발언이 아무런 제재 없이 계속된다면, 피해를 입는 이용자가 생기거나 일부는 게임에서 이탈할 수도 있다. 이런 상황이 반복되면 게임 커뮤니티가 붕괴되고, 게임을 운영하는 주체에 대한 신뢰도도 떨어질 수 있다.

결국 ToxMod 와 같은 음성 중재 AI 가 불러오는 윤리적 딜레마는, 이용자를 보호하기 위한 적극적 개입과, 표현의 자유 보장이라는 두 가치 사이에서 균형을 어떻게 잡을 것인가라는 과제에서 비롯된다. AI 기반 중재 시스템이 어디까지 개입할 것인지, 그리고 그 기준과 경계는 어떻게 정해야 할지에 대한 논의가 앞으로도 계속 필요할 것으로 보인다.

Ⅴ. 개선 사항 및 후속 조치 제안

1. 윤리적 문제에 대한 개선 방안

먼저, 투명성과 제재 절차의 정교화가 필요하다. AI 가 자동으로 판단하는 음성 중재 시스템은 때때로 이용자에게 실질적인 불이익을 줄 수 있기 때문에, 제재 사유와 판단 근거를 누구나 이해할 수 있게 충분히 설명해 주어야 한다. 단순히 결과만 통보하는 데 그치지 않고, 어떤 유형의 제재가 내려졌는지, 어떤 기준이 적용되었는지, 그리고 이의 제기가 가능한지 등도 자세히 안내하는 절차가 더 강화되어야 한다. 이용자의 권리를 보호하려면 이의 제기나 구제 절차도 누구나 쉽게 이용할 수 있도록 하는 방안이 필요하다. AI 의 오작동이나 오판이 있을 수 있다는 점을 고려하면, 만약 이용자가 부당한 제재를 받았다고 느낄 때 이를 바로잡을 수 있는 방법이 충분히 마련되어야 한다. 이런 절차는 시스템에 대한 신뢰를 지키는 데도 중요한 역할을 한다.

2. 제도적·기술적 보완 사항

기술적인 면에서는 학습 데이터의 편향을 줄이는 일이 중요한 과제로 꼽힌다. 음성 기반 AI 시스템은 억양이나 발음, 언어 습관, 문화적 표현 차이 때문에 특정 집단에 불리하게 작동할 수 있다. 그래서 다양한 언어권과 문화적 배경을 충분히 반영한 데이터를 확보하고, 꾸준히 성능을 점검해 오작동이나 오탐을 최소화하려는 노력이 필요하다. 또 자동화가 많이 이루어진 시스템일수록, 인간의 감독 역할을 어디까지 둘

것인지 분명히 정해두는 게 중요하다. AI 가 1 차적으로 유해 발언을 걸러내더라도, 최종적으로 제재할지 판단하거나 분쟁이 생기면 사람이 검토하고 결정할 수 있는 구조를 남겨둬야 책임 소재가 확실해진다.

제도적 측면에서는 개인정보 보호와 관련된 내부 정책을 좀 더 구체적으로 공개하고, 데이터의 보관과 폐기 기준도 명확히 제시해야 이용자들이 불안해하지 않는다. 이런 노력은 기업이 자율적으로 규범을 강화하는 동시에, 외부 규제 환경에 선제적으로 대응하는 데도 도움이 될 수 있다.

3. 평가의 한계 및 제약사항

본 평가는 공개된 자료와 문헌 분석을 토대로 진행되었기 때문에 몇 가지 한계와 제약이 뒤따랐다. 우선, 평가 대상인 ToxMod 를 실제로 사용해 보거나 운영 환경에서 직접 테스트하지 못한 점이 큰 한계였다. 이로 인해 음성 인식의 정확도, 잘못된 탐지 빈도, 제재 이후 이용자 경험과 같은 세부적인 운영 결과는 기업이 밝힌 자료나 사례 보고서에 의존할 수밖에 없었다.

또 이용자, 개발자, 운영자를 대상으로 설문조사나 인터뷰를 진행하지 못해, 다양한 이해관계자의 인식이나 체감 효과를 구체적이고 경험적으로 담아내는 데에도 어려움이 있었다. 특히 억울한 제재 경험이나 표현의 자유 위축, 제재 절차에 대한 수용성 등은 2 차 자료를 바탕으로 간접적으로 추정할 수밖에 없었다.

평가 시, Activision 과 Modulate 가 공개한 공식 문서, 사례 자료, 자주 묻는 질문 자료를 주요 근거로 사용하여 이 때문에 기업의 시각이 비교적 많이 반영되었을 수 있다. 외부 언론 보도나 학술 연구 결과 등을 통해 이를 어느 정도 보완하려 했으나, 알고리즘의 구체적인 작동 원리나 데이터 학습 과정 등은 공개되지 않아 충분히 검증하기는 어려웠다.

마지막으로, 이번 평가는 윤리적 영향에 대한 질적 분석에 초점을 맞추었으며, 정량적 성능 비교나 기술적 우수성 평가를 목적으로 하지는 않았다. 따라서 이 보고서의 결과는 기술적 완성도를 판가름하려는 것이 아니라, 온라인 게임 환경에서 AI 기반 음성 중재 시스템이 불러올 수 있는 윤리적 쟁점과 사회적 의미를 중심으로 읽어야 한다.

4. 후속 조치 및 정책 제언

장기적으로 보면 ToxMod 는 다국적 이용 환경에서 오탐이나 개인정보 보호와 관련된 문제가 생길 수 있기 때문에, 꾸준한 점검과 개선이 꼭 필요하다. 전 세계를 대상으로 한 서비스인 만큼, 언어와 문화의 차이에서 새로운 윤리적 이슈가 계속해서 등장할 수 있다. 그래서 정기적인 영향 평가와 외부 전문가의 검토 등을 통해 시스템 운영을 꼼꼼히 살피는 체계가 마련되어야 한다. 그리고 기업이 AI 중재 시스템을 운영하면서 얻은 경험이나 개선 결과를 일정 수준에서 공개하면, 이용자뿐만 아니라 다양한 이해관계자와의 신뢰도 높아진다. 이렇게 투명하게 정보를 공유하는 과정은 앞으로 AI 콘텐츠 중재와 관련된 정책 논의나 사회적 합의에도 긍정적인 역할을 할 수 있다.

결국 ToxMod 가 이용자 보호라는 본래 목적을 지키면서, 투명성을 높이고 공정성과 개인정보 보호까지 신경 쓴다면 더 신뢰받는 AI 중재 시스템으로 자리잡을 수 있을 것이다.

참고문헌

1. 개인정보보호위원회. (2021). *인공지능(AI) 개인정보보호 자율점검표* (2021. 5. 제정). Retrieved from https://www.privacy.go.kr/front/bbs/bbsView.do?bbsNo=BBSMSTR₩_000000000049₩&bbscttNo=12468
2. 개인정보보호위원회. (2022). *우리 기업을 위한 EU 일반 개인정보보호법(GDPR) 가이드북* (2022. 12. 개정). Retrieved from https://www.privacy.go.kr/front/bbs/bbsView.do?bbsNo=BBSMSTR₩_000000000049₩&bbscttNo=14518
3. 개인정보보호위원회. (2025). *개인정보 영향평가 수행안내서* (2025. 10. 개정). Retrieved from https://www.kisa.or.kr/2060301/form?postSeq=63₩&langW_type=KO
4. 과학기술정보통신부. (2018). *지능정보사회 윤리 가이드라인 및 지능정보사회 윤리현장*. Retrieved from https://www.msit.go.kr/bbs/view.do?sCode=user₩&bbsSeqNo=65₩&nttSeqNo=1410203
5. 국가인권위원회. (2021). *온라인 혐오표현 인식조사*. 국가인권위원회.
6. 국가법령정보센터. (n.d.). *개인정보 보호법 조문정보*. Retrieved from https://www.law.go.kr/lsLawLinkInfo.do?chrClsCd=010202₩&lsJoLnkSeq=1000575255
7. 국회도서관 의회법률정보포털. (n.d.). *미국 일리노이주 생체정보 개인정보 보호법 (BIPA)*. Retrieved from https://law.nanet.go.kr/foreignlaw/foreignIndex/foreignIndexView.do?countPerPage=10₩&cn=TLAW1202100724
8. 김미선, 이도영, 이종원. (2019). *온라인 게임 내 혐오표현과 게임문화 개선에 대한 연구*. 한국컴퓨터정보학회, 27(2), 299-302.
9. 김수연. (2025). *"인공지능 썼으면 밝히세요" 정부, 'AI 기본법 시행령' 입법예고*. 세계일보. Retrieved from https://www.segye.com/newsView/20251112513535?OutUrl=naver
10. 김희재. (2025). *데이터 윤리와 보안* [10 주차 강의자료 (PPT)]. 서울여자대학교.
11. 박기령. (2015). *혐오발언(hate speech)의 정의 및 표현의 자유에 관한 법제이슈*. 법제이슈브리프, 2015(3), 1-4.
12. 박현아. (2025). *온라인게임의 혐오표현과 규제 — 심층인터뷰를 통한 탐색적 연구 —*. 언론과 법, 24(2), 87-126.
13. 세계법제정보센터. (2025). *EU 인공지능법*. Retrieved from https://world.moleg.go.kr/web/wli/lgslInfoReadPage.do?CTS₩_SEQ=51409₩&AST₩_SEQ=93
14. 세계법제정보센터. (n.d.). *아동의 온라인 개인정보 보호법(Children's Online Privacy Protection Act)*. Retrieved from https://world.moleg.go.kr/web/wli/lgslInfoReadPage.do?CTS₩_SEQ=49736₩&AST₩_SEQ=313

15. 손영화. (2023). *AI 공정성에 관한 연구-차별 없는 AI 사회의 실현-*. Hanyang Law Review, 34(3), 83. Retrieved from https://www-dbpia-co-kr.libproxy.swu.ac.kr/journal/articleDetail?nodeId=NODE11516111
16. 유럽연합(EU). (n.d.). *인공지능(AI) 윤리 가이드라인*.
17. 이재진. (1999). 혐오언론(hate speech) *현상에 대한 법제론적 고찰*. 언론학보 통권 제 19 호, 99-125.
18. 이창호 외. (2014). *청소년의 생성형 AI 이용실태 및 리터러시 증진방안 연구.* (연구보고 24-기본 02). 한국청소년정책연구원. Retrieved from https://nypi.re.kr/brdrr/boardrrView.do?menu₩_nix=4o9771b7₩&brd₩_id=BDIDX₩_PJk7xvf7L096m1g7Phd3YC₩&tab=
19. 인공지능 발전과 신뢰 기반 조성 등에 관한 기본법, 법률 제 20676 호 (2025).
20. 정보통신용어사전. (n.d.). *정보통신용어사전*. Retrieved from http://word.tta.or.kr/main.do
21. 조선일보. (2025). *연인에게도 안 보여준다는 '챗 GPT 고민 상담'*. Retrieved from https://www.chosun.com/national/national₩_general/2025/07/01/YJHB553E3ZCLHOKMJMOF3UHEYY/?utm₩_source=naver₩&utm₩_medium=referral₩&utm₩_campaign=naver-news
22. 한국정보통신기술협회. (n.d.). *2024 신뢰할 수 있는 인공지능 개발안내서 - 일반 분야*.
23. 황정우, 임화섭. (2016). *인공지능 세뇌의 위험…MS 채팅봇 '테이' 차별발언으로 운영중단*. 연합뉴스. Retrieved from https://www.yna.co.kr/view/AKR20160325010151091
24. 홍장원. (2014). *[스마트 선거] 오바마 再選은 빅데이터의 승리*. 매일경제. Retrieved from https://www.mk.co.kr/news/it/6108789
25. Activision. (n.d.). *콜 오브 듀티 음성 채팅 중재 FAQ*. Activision 지원. Retrieved from https://support.activision.com/ko/articles/call-of-duty-voice-chat-moderation
26. Activision. (n.d.). *개인정보 보호정책*. Retrieved from https://www.activision.com/ko/legal/privacy-policy
27. Activision. (n.d.). *청소년용 개인정보 보호정책*. Retrieved from https://www.activision.com/ko/legal/privacy-young-people
28. Angwin, J., Larson, J., Mattu, S., & Kirchner, L. (2016). *Machine bias*. ProPublica. Retrieved from https://www.propublica.org/article/machine-bias-risk-assessments-in-criminal-sentencing
29. Call of Duty Staff. (2023). *유해성 근절 진행 보고서 - 음성 채팅 중재*. Retrieved from https://www.callofduty.com/ko/blog/2023/08/call-of-duty-modern-warfare-warzone-anti-toxicity-progress-report
30. Chin, M. (2023). *Call of Duty will use AI to moderate voice chats*. The Verge. Retrieved from https://www.theverge.com/2023/8/30/23852652/call-of-duty-activision-modulate-toxmod-artificial-intelligence-voice-moderation
31. Dastin, J. (2018). *Amazon scraps secret AI recruiting tool that showed bias*

against women. Reuters. Retrieved from https://www.reuters.com/article/us-amazon-com-jobs-automation-insight/amazon-scraps-secret-ai-recruiting-tool-that-showed-bias-against-women-idUSKCN1MK08G/
32. Edwards, B. (2023). *AI-powered hate speech detection will moderate voice chat in Call of Duty*. Ars Technica. Retrieved from https://arstechnica.com/information-technology/2023/08/ai-powered-hate-speech-detection-will-moderate-voice-chat-in-call-of-duty/#p3
33. European Parliament and Council. (2024). *Regulation (EU) 2024/1689 of the European Parliament and of the Council of 13 June 2024 laying down harmonised rules on artificial intelligence and amending Regulations (EC) No 300/2008, (EU) No 167/2013, (EU) No 168/2013, (EU) 2018/858, (EU) 2018/1139 and (EU) 2019/2144 and Directives 2014/90/EU, (EU) 2016/797 and (EU) 2020/1828 (Artificial Intelligence Act)*. Retrieved from https://world.moleg.go.kr/web/wli/lgsIInfoReadPage.do?CTS₩_SEQ=51409₩&AST₩_SEQ=93
34. Kowert & Woodwell. (2022). *Prevalence of offensive behaviors in voice chat*. Take This & Modulate report. Retrieved from https://www.takethis.org/wp-content/uploads/2022/12/takethismodulatereport.pdf
35. McKenzie. (2024). *Activision uses AI to ban racial slurs in Call of Duty voice chats*. 80 Level. Retrieved from https://80.lv/articles/activision-uses-ai-to-ban-racial-slurs-in-call-of-duty-voice-chats
36. Modulate. (n.d.). *Modulate and Activision case study*. Modulate. Retrieved from https://www.modulate.ai/case-studies/modulate-activision-case-study
37. Modulate. (n.d.). *Modulate virtual patent marking*. Retrieved from https://www.modulate.ai/legal
38. Modulate. (n.d.). *Privacy and data management*. Retrieved from https://www.modulate.ai/privacy-and-data
39. Modulate. (n.d.). *Privacy policy*. Retrieved from https://www.modulate.ai/privacy-policy
40. Modulate. (n.d.). *ToxMod*. Retrieved from https://www.modulate.ai/products/toxmod
41. Modulate. (n.d.). *ToxMod in action*. Retrieved from https://www.modulate.ai/products/toxmod#book-a-d
42. Modulate. (n.d.). *ToxMod 기술 보고서*. Retrieved from https://cdn.prod.website-files.com/67ed675f8e30d86d14c51adb/67f52e44b1fcc1a577794311₩_Modulate%20-%20What%20is%20Proactive%20Moderation.pdf
43. Sparrow et al. (2024). *Towards ethical AI moderation in multiplayer games*. Proceedings of the ACM on Human-Computer Interaction, 344(8), 1-30. Retrieved from https://dl.acm.org/doi/10.1145/3677109
44. Trithara, D. (2024). *Agents of platform governance: Analyzing U.S. civil society's role in contesting online content moderation*. Telecommunications Policy, 48(4), Article 102735. Retrieved from https://doi.org/10.1016/j.telpol.2024.102735