보이스피싱 분석 프로젝트

데이터사이언스학과 서채은
데이터사이언스학과 이지현

Contents

01

주제 소개

배경 이론 및 주제 구체화,
목표 소개

02

데이터 수집

csv 데이터, 음성 및 영상 데이터,
스크립트 데이터 상세정보 설명

03

데이터 전처리

영상 데이터 및 음성 데이터 변환,
csv 전처리 과정 소개

04

향후 진행 계획

앞으로 나아갈 방향과 구체적인
계획 소개

보이스피싱 분석 프로젝트

배경 이론 및 주제 구체화, 목표 소개



▲ 서사케 외 2명, 경찰학연구 제 21권 제 4호(2021)

▲ 더치트, 출퀘이천 천자 (2021.06 기사)

- 해미

2016년
해액이
나고 있

- 보이

보이스
지급 정지 등의 절차가 있지만, 이는 돈이 빠
져나가기 전에만 가능하며 이미 돈을 인출했
다면 되돌려받기는 어려움

- 더치트의 사기 피해 사례 제공

보이스피싱 피해 사례는 내용 열람이 제공되
지 않아 신종 사기 유형부터 기존에 있던 유
형까지도 방지하기 어려움

- 보이스피싱 피해 사례 공유 커뮤니티 구축

표

비슷한
는 기능

범죄 시행
나눠 각
법의 패턴

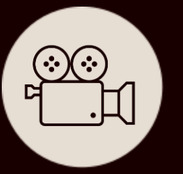
고 있습니다.

종 사기

	A	B	C	D	E
1	title	author	publish_date	keywords	description
2	[※공개수배]	비디오머	2018-07-17 0:00	['뉴스', 'NI	금융감독원이 보이스
3	보이스 피싱	옆집아들	2022-05-01 0:00	['성폭행',	피싱(전화금융사기)사
4	실제 보이스피	펀주부fun	2021-07-07 0:00	['보이스피	었" #보이스피싱 #보이스
5	보이스 피싱	오동훈TV	2021-06-04 0:00	['몰카', '예	피싱참고영상 #보이스피 #보이스피싱 #보이스
6	보이스피싱 '[	엠빅뉴스	2021-05-18 0:00	['보이스피	#영광광고 금융감독원이 제공하
7	보이스피싱 시	노티시아E	2015-02-12 0:00	['voice ph	는 잘찾아봉인실피싱을
8	[보이스피싱 시	시니어금융	2020-12-09 0:00	[]	보이스피싱에관 "사건
9	[실제 피해음	금융위원회	2019-06-19 0:00	['금융위원	의 실제 사기범을 알려
10	100%리얼-올	짧은팁날	2022-03-20 0:00	['보이스피	과 계좌 지급정지 합동 캠페인
11	"이건 진짜 나	KBS News	2022-05-27 0:00	['KBS', 'KB	송 KBS 하차 당시 문자
12	[보이스피싱 시	시니어금융	2020-12-09 0:00	[]	지금 본 보이스
13	22년 신종 보	임관장의	2022-02-25 0:00	['신종보이	#실제 사기범을 알려
14	[보이스피싱 시	시니어금융	2020-12-09 0:00	[]	이 #보이스피싱 #보이스
15	[시청자브리핑	YTN	2020-07-02 0:00	['YTN']	실제 사기범을 알려
16	보이스피싱 대	KBS시사	2021-07-04 0:00	['시사다큐	에 공조하게 됩니다 120
17	"이건 진짜 나	크랩 KLAB	2022-04-08 0:00	['크랩', '보	만 #보이스피싱 #공제
18	'교활해진 그놈	YTN	2021-05-17 0:00	['source:영	공제]
19	지능형 보이스	철인태경	2019-11-12 0:00	['철인태경	절대 속지 마세요! 1금
20	3차례 신고된	보이스피싱	2021-01-04 0:00	['보이스피	실제 보이스피싱 사기
21	"유포할까요?	whoscall후	2015-12-17 0:00	[]	범 유선등 피해를 막는
22	2020.11.05. 노	Houyhnhr	2020-11-04 0:00	[]	최선의 방법
23	6차례 신고된	보이스피싱	2021-01-04 0:00	['보이스피	보이스피싱 신고는 http
24	모르면 100%	버미쌤	2020-11-19 0:00	['메신저 피	실제 보이스피싱 사기
25	금감원, 보이스	연합뉴스T	2015-07-30 0:00	['Yonhapn	범 음성등 피해를 막는
26	▶(음성 재생)	THE FACT	2015-06-26 0:00	[]	미나 없는 문자에 이런
27	4차례 신고된	보이스피싱	2021-01-04 0:00	['보이스피	몸짱엔 속아 최규정 그녀 목소리 공개
					실제 보이스피싱 사기
					범 음성등 피해를 막는
					실제 보이스피싱 사기

데이터 수집

크롤링한 csv 데이터 소개



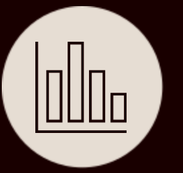
- **사용한 라이브러리**

pytube - YouTube 동영상을 다운로드하기 위한 경량의 종속성 없는 라이브러리



- **데이터 건 수**

500건



- **컬럼명 소개**

title, author, publish_date, keywords, description



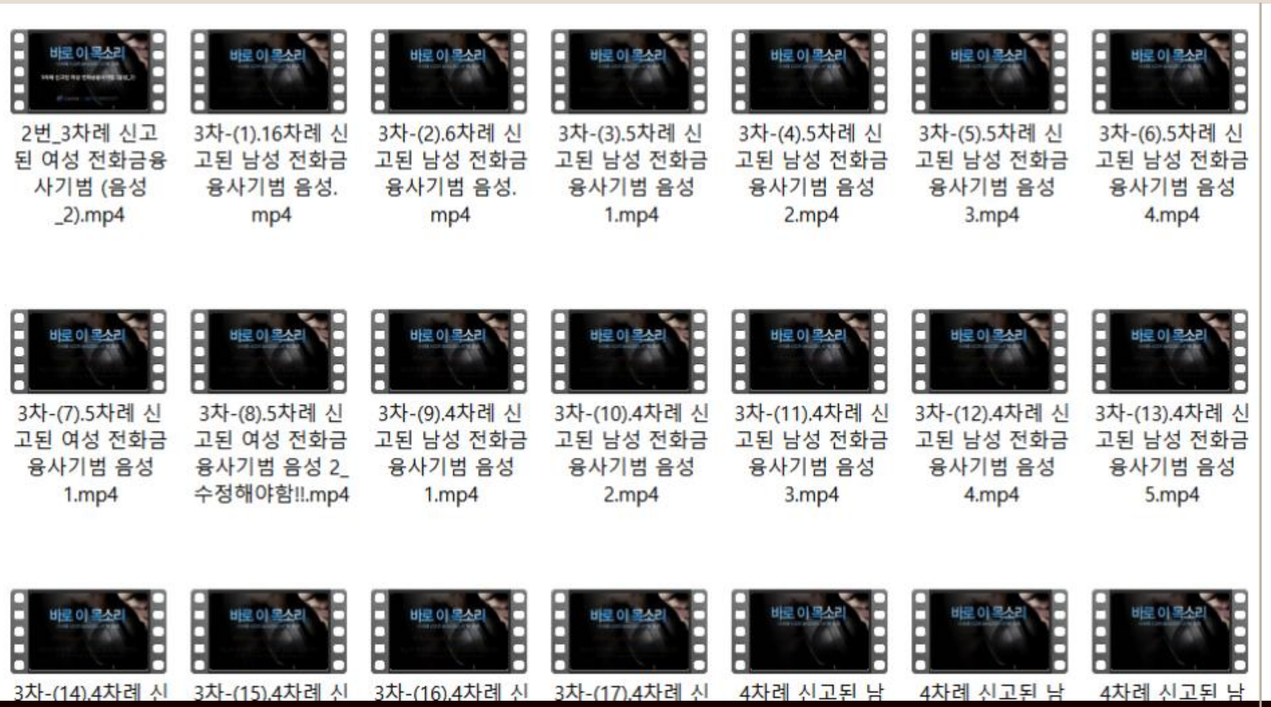
- **데이터 수집 방법**

유튜브 사이트에서 '보이스피싱 음성' 검색 후 영상 500건 크롤링

데이터 수집

음성 및 영상 데이터 상세정보

영상 데이터 상세정보

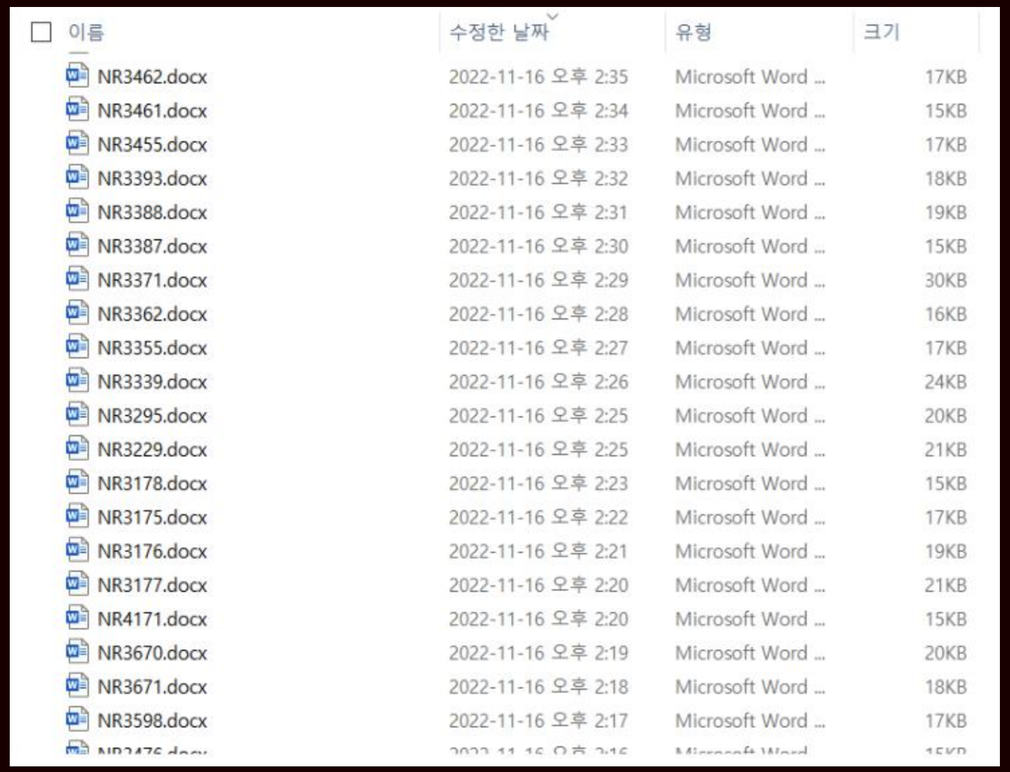


- 데이터 건 수 : 82건
- 데이터 용량 : 13.7GB
- 데이터 유형 : mp4 (비정형 데이터)
- 데이터 수집처 : 금융감독원 홈페이지
- 데이터 상세정보 : 가장 짧은 영상 - 1분 9초
  가장 긴 영상 - 8분 34초

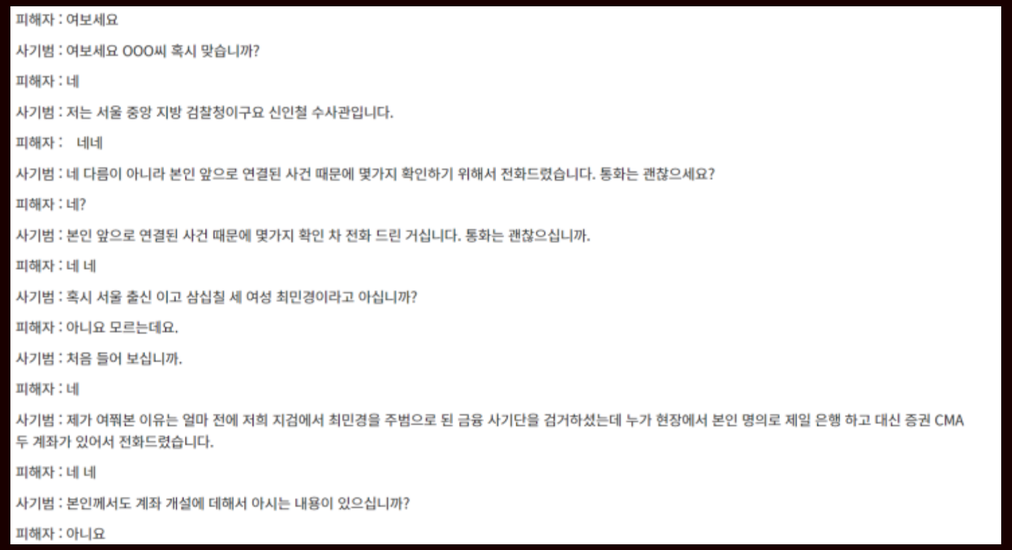
음성 데이터 상세정보



- 데이터 건 수 : 420건
- 데이터 용량 : 1.88GB
- 데이터 유형 : mp3 (비정형 데이터)
- 데이터 수집처 : 금융감독원 홈페이지
- 데이터 상세정보 : 가장 짧은 음성 - 11초
  가장 긴 음성 - 1시간 49초



이름	수정한 날짜	유형	크기
NR3462.docx	2022-11-16 오후 2:35	Microsoft Word ...	17KB
NR3461.docx	2022-11-16 오후 2:34	Microsoft Word ...	15KB
NR3455.docx	2022-11-16 오후 2:33	Microsoft Word ...	17KB
NR3393.docx	2022-11-16 오후 2:32	Microsoft Word ...	18KB
NR3388.docx	2022-11-16 오후 2:31	Microsoft Word ...	19KB
NR3387.docx	2022-11-16 오후 2:30	Microsoft Word ...	15KB
NR3371.docx	2022-11-16 오후 2:29	Microsoft Word ...	30KB
NR3362.docx	2022-11-16 오후 2:28	Microsoft Word ...	16KB
NR3355.docx	2022-11-16 오후 2:27	Microsoft Word ...	17KB
NR3339.docx	2022-11-16 오후 2:26	Microsoft Word ...	24KB
NR3295.docx	2022-11-16 오후 2:25	Microsoft Word ...	20KB
NR3229.docx	2022-11-16 오후 2:25	Microsoft Word ...	21KB
NR3178.docx	2022-11-16 오후 2:23	Microsoft Word ...	15KB
NR3175.docx	2022-11-16 오후 2:22	Microsoft Word ...	17KB
NR3176.docx	2022-11-16 오후 2:21	Microsoft Word ...	19KB
NR3177.docx	2022-11-16 오후 2:20	Microsoft Word ...	21KB
NR4171.docx	2022-11-16 오후 2:20	Microsoft Word ...	15KB
NR3670.docx	2022-11-16 오후 2:19	Microsoft Word ...	20KB
NR3671.docx	2022-11-16 오후 2:18	Microsoft Word ...	18KB
NR3598.docx	2022-11-16 오후 2:17	Microsoft Word ...	17KB



피해자 : 여보세요

사기범 : 여보세요 OOO씨 혹시 맞습니까?

피해자 : 네

사기범 : 저는 서울 중앙 지방 검찰청이구요 신인철 수사관입니다.

피해자 : 네네

사기범 : 네 다름이 아니라 본인 앞으로 연결된 사건 때문에 몇가지 확인하기 위해서 전화드렸습니다. 통화는 괜찮으세요?

피해자 : 네?

사기범 : 본인 앞으로 연결된 사건 때문에 몇가지 확인 차 전화 드린 거십니다. 통화는 괜찮으십니까.

피해자 : 네 네

사기범 : 혹시 서울 출신 이고 삼십칠 세 여성 최민경이라고 아십니까?

피해자 : 아니요 모르는데요.

사기범 : 처음 들어 보십니까.

피해자 : 네

사기범 : 제가 여쭤본 이유는 얼마 전에 저희 지검에서 최민경을 주범으로 된 금융 사기단을 검거하셨는데 누가 현장에서 본인 명의로 제일 은행 하고 대신 증권 CMA 두 계좌가 있어서 전화드렸습니다.

피해자 : 네 네

사기범 : 본인께서도 계좌 개설에 데해서 아시는 내용이 있으십니까?

피해자 : 아니요

데이터 수집

스크립트 데이터 상세정보

- **데이터 건 수 및 용량**

건 수 : 126건

용량 : 1.8MB

- **데이터 유형**

docx (Word 파일, 비정형 데이터)

- **데이터 수집처**

금융감독원 홈페이지

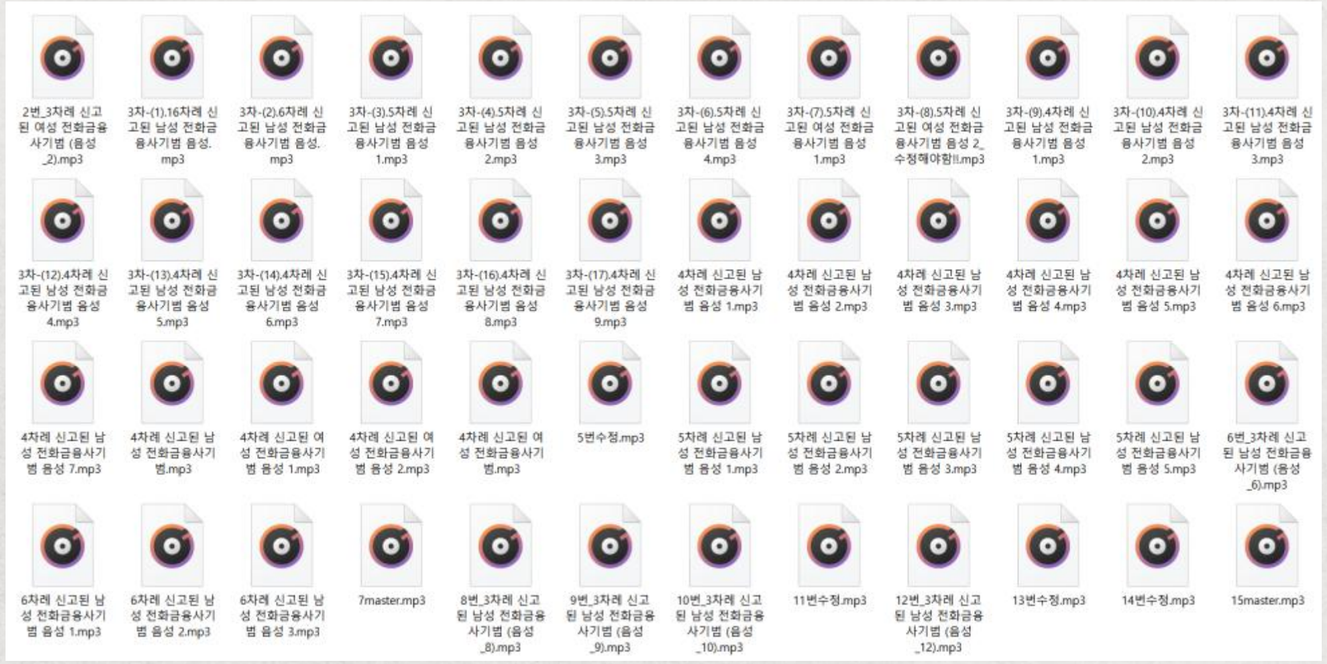
- **데이터 상세정보**

대출 사기 유형과 수사기관 사칭 유형으로 구분하여 데이터 수집

데이터 전처리

mp4 파일을 mp3 파일로 전처리

: 분석에 필요한 데이터는 음성 데이터이기 때문에 mp4 파일의 유형을 mp3로 변환하는 과정 수행



▲ 전처리 한 음성 파일

▪ 사용한 프로그램 - Filmora

영상 편집 소프트웨어인 Filmora 이용

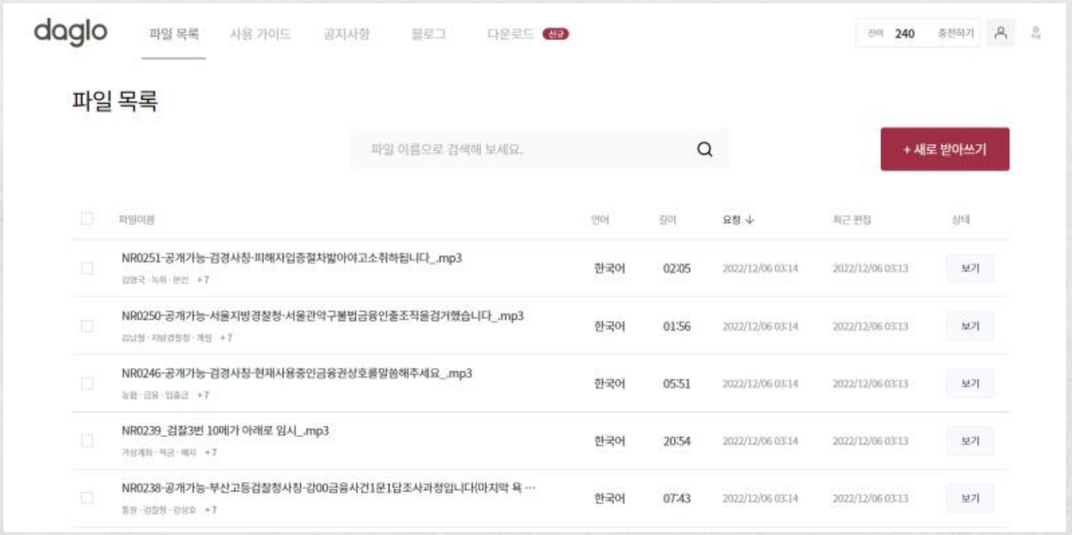
▪ 전처리 건 수

앞서 수집한 82건의 mp4 파일 모두 mp3로 전처리

데이터 전처리

mp3 파일을 텍스트 파일로 전처리

: 음성 파일을 텍스트 파일로 변환시켜주는 daglo 프로그램 (STT 프로그램) 활용



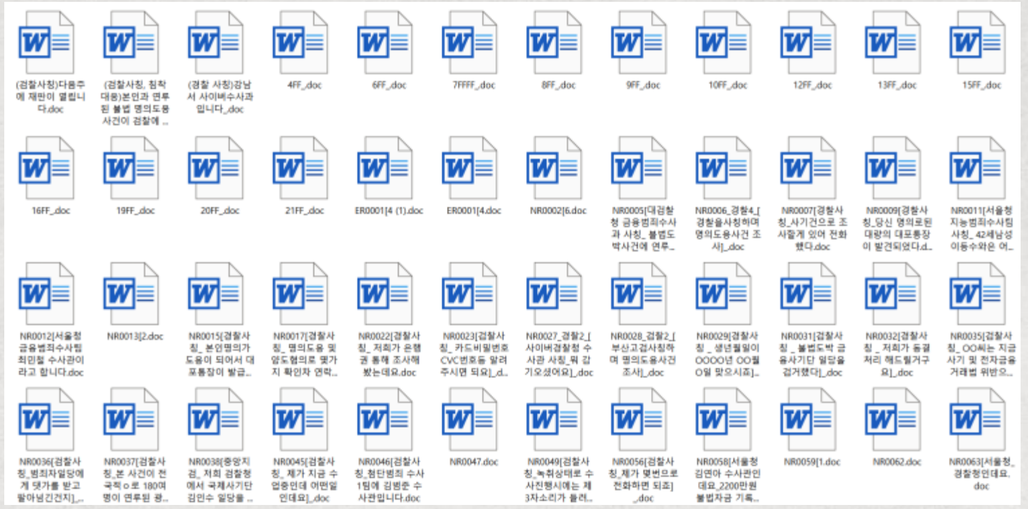
▲ daglo 프로그램 사용 화면

▪ Speech to Text

범죄 과정 중에 범죄자가 자주 하는 말을 분석하기 위한 데이터 전처리 과정 수행

▪ 전처리 건 수

앞서 mp4에서 mp3로 전처리한 82건의 데이터와 기존에 수집한 420건의 mp3 데이터까지 총 502건 전처리 수행



▲ 전처리 한 docx 파일

데이터 전처리

pandas를 이용한 csv 데이터 전처리

pandas 라이브러리 호출, 크롤링한 csv 불러오기

↓

중복되는 행 전처리

↓

title에 '보이스피싱' 또는 '보이스 피싱'을 포함하지 않을 시 해당 행 제거

↓

title에 '참교육', '역관광', '몰카' 등 주작 및 유머 영상물을 예상케하는 단어가 포함되어 있는 행 제거

↓

keywords에 '참교육', '역관광', '몰카' 등 주작 및 유머 영상물을 예상케하는 단어가 포함되어 있는 행 제거

↓

description이 null값인 행 제거

↓

publish_date에서 '0:00' 제거 후 csv 저장

```
[ ] # 폴더 이동
[ ] df2['publish_date'] = df2['publish_date'].str.replace('0:00', '')
    df2
```

```
<ipython-input-16-c3abd3fb240a>:1: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
  df2['publish_date'] = df2['publish_date'].str.replace('0:00', '')
```

	title	author	publish_date	keywords	description
0	[※공개수배] 보이스피싱 실제음성 대공개 / 비디오머그	비디오머그 - VIDEOMUG	2018-07-17	['뉴스', 'NEWS', 'SBS', 'SBS NEWS', '비디오머그', 'VI...	금융감독원이 보이스피싱(전화금융사기) 사기범 17명의 목소리를 공개 수배했습니다. ...
1	보이스 피싱 당해서 2천원 날렸습니다 (영상 보시고 여러분은 제발 당하지 마세요)	엽집아들	2022-05-01	['성폭행', '보이스피싱', '피싱', '보이스', '사기', '범죄', '조선족...	"오빠 나 성폭행 당했어."₩n울며 전화하는 아내 목소리를 듣고 한 순간에 정신이 ...
4	보이스피싱 '미공개 육성파일' 17개가 나왔다!!! 들으면 '진짜라고 믿게 된다'는...	엠빅뉴스	2021-05-18	['보이스피싱', '피싱', '금융감독원', '그놈목소리', '육성파일', '연변'...	금융감독원이 새롭게 등장한 보이스피싱 유형 17개를 전격 공개했습니다. 과거 연변 ...
5	보이스피싱 사례 - 음성공개 (경찰청사칭 보이스피싱)	노티시아티비(Noticia TV)	2015-02-12	['voice phishing', '보이스피싱', '금융사기 20140130김명철'...	서울지방경찰청사칭 보이스피싱이며, "사건번호 20140130 김명철 명의도용사건" ...
6	[보이스피싱 사기범 제보요청] 전화금융사기범 음성_04(여성, 5차례 신고)	시니어금융교육협의회	2020-12-09	[]	지금 듣고 계신 목소리의 실제 사기범을 아래 주소로 신고하세요!₩n포상금 2천만원!...
...	...	...	...	...	...
455	MBC경남 뉴스데스크 2014 11 02 보이스피싱 예방 '통신사가 앞장'	구 MBCGN	2014-11-02	['MBC경남', 'MBC', '뉴스데스크', '뉴스', '진주', '창원', '경...	MBC경남 뉴스데스크(2014.11.02)₩n₩n한동안 주춤했던 보이스피싱,₩n즉 ...
456	보이스피싱 등 전자금융사기는 피해자의 100% 책임?	힙합팬	2017-01-28	['공정위', '전자금융', '보이스피싱', '파밍', '대법원', '대법원 판결'...	공정위 전자금융거래 약관 개정했다는 것? 보여주기식일 뿐입니다₩n₩n공정위에서 보이...
460	보이스피싱 아이돌 전달책 중간책 범행 가담 자수..과연 처벌은?	소송가이드	2022-07-14	[]	#보이스피싱아이돌 #보이스피싱전달책 #보이스피싱중간책₩n★변호사 무료 상담신청₩nh...
473	메이킹액터 동아리, [고객님 계좌에서 3천만원이...], 보이스피싱 전화사기단, 개...	서일문화예술고 뮤지컬연기과	2021-10-14	[]	서일문화예술고등학교 뮤지컬연기과 공식 유튜브 채널입니다. 정말 오랜만에 영상을 업로...
490	※고난이도 듣기평가※ 다음중 '진짜' 보이스피싱범은? 여러분도 풀어보세요 #보이스피...	YTN 라디오	2022-11-10	[]	#ytn뉴스 뉴스 라디오(FM 94.5) [YTN 뉴스FM 슬기로운 라디오생활]₩n...

278 rows × 5 columns

```
[ ] df2.to_csv("유튜브크롤링_전처리.csv", encoding='cp949')
```

500 rows × 5 columns

```
df2 = df1[df1['keywords'].str.contains('참교육|역관광|유머|개그|몰카|몰래카메라|
                                       ...|몰래|카메라|ㄱ')].index
df2.to_csv("유튜브크롤링_전처리.csv", encoding='cp949')
```

→ 300 rows x 5 columns

향후 진행 계획

유튜브 음성 추출

전처리한 유튜브 영상 리스트 음성 수집



불필요한 음성 전처리

피해자 목소리와 개인정보 보호로 인한 대체 음성 전처리



스크립트 데이터 전처리

오타 제거 및 화자 설정 전처리



음성 분석 스터디 진행

향후 음성 분석을 위한 방학 중 스터디 진행



음성 및 스크립트 데이터 분석

범죄자의 말투와 화법 등의 패턴 분석



어플리케이션 설계 및 개발

앱 개발을 위한 최종적인 시스템 설계



출처 정보

논문 자료
https://www.dbpia.co.kr/journal/voisDetail?voisId=VOIS00670328

기사 자료
https://bravo.etoday.co.kr/view/atc_view/14034
https://www.yna.co.kr/view/AKR20221005168800004
http://www.nspna.com/news/?mode=view&newsid=552544
https://eiec.kdi.re.kr/policy/materialView.do?num=230732&topic=
http://www.sisacast.kr/news/articleView.html?idxno=35461

금융감독원
https://www.fss.or.kr/fss/bbs/B0000203/list.do?menuNo=200686

THECHEAT
https://thecheat.co.kr/rb/?m=bbs&bid=phishing

Q&A

들어주셔서감사합니다

데이터사이언스학과 [redacted] 서채은
데이터사이언스학과 [redacted] 이지현

